



دانشگاه صنعتی امیرکبیر

(پلی تکنیک تهران)

دانشکده مهندسی کامپیوتر

پروژه تحقیقاتی درس سمینار

روش‌های خلاصه‌سازی انتزاعی

نگارش

زهرا زنجانی

استاد درس

دکتر رضا صفابخش

شهریور ۱۴۰۲

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

# فهرست مطالب

صفحه

عنوان

۱	مقدمه	۱
۱	۱-۱ مقدمه	۱
۱	۲-۱ چشم‌انداز نوشتار	۱
۲	۲ روش‌های مبتنی بر ساختار	۲
۳	۱-۲ روش مبتنی بر درخت	۳
۳	۲-۲ روش مبتنی بر قالب	۳
۴	۳-۲ روش مبتنی بر هستان شناسی	۴
۴	۴-۲ روش عبارت مقدمه و بدنه	۴
۴	۵-۲ روش مبتنی بر گراف	۴
۵	۶-۲ روش مبتنی بر قانون	۵
۶	۳ روش‌های مبتنی بر شبکه‌ی عصبی عمیق	۶
۷	۱-۳ روش‌های مبتنی بر مدل کدگذار-کدگشا	۷
۹	۲-۳ روش‌های مبتنی بر مدل ترنسفورمر	۹
۱۶	۱-۲-۳ ایده‌های ارائه شده بهبود خلاصه‌سازی متون طولانی	۱۶
۲۱	۴ روش‌های مبتنی بر یادگیری تقویتی	۲۱
۲۲	۱-۴ یادگیری تقویتی برای حل مسائل عمیق توالی به دنباله	۲۲
۲۳	۲-۴ یادگیری تقویتی برای ترکیب خلاصه‌های استخراجی و انتزاعی	۲۳
۲۴	۳-۴ یادگیری تقویتی برای ایجاد معیارها و پاداش‌های جدید	۲۴
۲۵	۴-۴ یادگیری تقویتی برای ایجاد خلاصه متناسب با نیاز کاربر	۲۵
۲۸	۵ جمع‌بندی	۲۸
۳۰	منابع و مراجع	۳۰
۳۶	واژه‌نامه‌ی انگلیسی به فارسی	۳۶
۳۹	واژه‌نامه‌ی انگلیسی به فارسی	۳۹

شکل	فهرست اشکال	صفحه
۱-۳	معماری پایه‌ی مدل کدگذار-کدگشا [۸]	۷
۲-۳	معماری پایه‌ی مدل دوگانه‌ی کدگذار [۳۳]	۸
۳-۳	معماری پایه‌ی مدل سلسله‌مراتبی متغیر برای خلاصه‌سازی متقابل زبانی [۱۵]	۹
۴-۳	معماری مدل تی‌برت‌سام [۱۹]	۱۰
۵-۳	تعبیه مدل تی‌برت‌سام [۱۹]	۱۱
۶-۳	معماری ترنسفورمر تی‌برت‌سام [۱۹]	۱۲
۷-۳	چهارچوب ایجاد خلاصه با طول متغیر [۳۰]	۱۳
۸-۳	عمل‌های پیش‌آموزش بارت [۱۴]	۱۴
۹-۳	ساختار مدل پگاسوس [۳۵]	۱۵
۱۰-۳	الگوریتم امداد [۲۸]	۱۶
۱۱-۳	معماری مدل ترنسفورمر از بالا به پایین [۲۳]	۱۸
۱۲-۳	لایه خودتوجهی تقویت شده ادغام شده [۳۲]	۲۰
۱-۴	یک نمونه از نمودار منحنی بازیابی بر اساس طول [۲۷]	۲۶
۲-۴	معماری مدل ام‌سام [۲۶]	۲۷

# فصل اول

## مقدمه

## ۱-۱ مقدمه

با رشد روزافزون اینترنت، حجم محتوای متنی در اینترنت (به عنوان مثال وب سایت‌ها، اخبار، وبلاگ‌ها، شبکه‌های رسانه‌های اجتماعی و غیره) به صورت تصاعدی افزایش می‌یابد. در نتیجه، کاربران زمان زیادی را صرف یافتن اطلاعات مورد نظر خود می‌کنند و نمی‌توانند تمام محتوای متنی نتایج جستجو را بخوانند. خلاصه‌سازی خودکار اسناد می‌تواند به شناسایی مهم‌ترین اطلاعات و صرفه‌جویی در وقت خوانندگان کمک کند. خلاصه‌سازی خودکار متن فرآیند تولید یک متن کوتاه است که بخش‌های اصلی یک سند طولانی‌تر را پوشش می‌دهد. یک خلاصه خوب جنبه‌های مهمی مانند خوانایی، انسجام، نحو، غیر زائد بودن، ترتیب جملات، مختصر بودن، تنوع اطلاعات و پوشش اطلاعات را در نظر می‌گیرد [۳].

در سال‌های گذشته تلاش‌های زیادی برای تولید خلاصه‌سازی خودکار قابل قبول و خوانا صورت گرفته است. پژوهش‌های مرتبط با عمل خلاصه‌سازی خودکار متن در دهه ۵۰ میلادی شکل گرفتند. در یکی از این پژوهش‌ها لوهن و همکاران روشی برای خلاصه‌سازی اسناد علمی ارائه دادند که در آن تابعی بر اساس فرکانس تکرار کلمات یا عبارات به عنوان ویژگی تعریف می‌شود و وزن‌های مرتبط با این ویژگی‌ها خلاصه استخراج می‌شود [۱۸]. در کارهای تحقیقاتی اولیه، مدل‌های غیرعصبی مبتنی بر ساختار برای تولید خلاصه‌سازی خودکار مورد استفاده قرار گرفتند. با شروع دوره‌ی شبکه‌های عصبی عمیق پژوهش‌ها بر روی خلاصه‌سازی بیشتر شد. رویکردهای نوین خلاصه‌سازی شامل شبکه‌های عصبی عمیق دنباله به دنباله<sup>۱</sup>، روش‌های بر پایه‌ی مدل ترنسفورمر<sup>۲</sup> و مدل‌های زبانی از پیش آموزش دیده<sup>۳</sup> می‌باشد. همچنین برخی از پژوهش‌های اخیر نشان داده‌اند، استفاده از رویکردهای مبتنی بر یادگیری تقویتی<sup>۴</sup> می‌تواند موجب بهبود معیارهای مختلف، از جمله امتیازات روژ، کیفیت کلی، خوانایی، انسجام، نحو، غیر افزونگی، ترتیب جملات، مختصر بودن، تنوع اطلاعات، پوشش اطلاعات شود.

## ۲-۱ چشم‌انداز نوشتار

در این گزارش، به بررسی مدل‌های مختلف برای خلاصه‌سازی انتزاعی می‌پردازیم که در چند فصل مختلف مورد بررسی قرار می‌گیرند. در فصل دوم، چندین روش مبتنی بر ساختار برای خلاصه‌سازی انتزاعی مورد بررسی قرار می‌گیرد. در فصل سوم روش‌های مبتنی بر شبکه‌های عصبی برای خلاصه‌سازی انتزاعی از جمله روش‌های مبتنی بر مدل‌های کدگذار-کدگشا و ترنسفورمر بررسی می‌شوند. در فصل چهارم روش‌های مبتنی بر یادگیری تقویتی مطرح می‌شود و در نهایت در فصل پنجم جمع‌بندی و مروری بر مطالب این گزارش خواهد بود.

<sup>1</sup>Deep neural sequence to sequence models

<sup>2</sup>transformer

<sup>3</sup>Pretrained language models (PTLMs)

<sup>4</sup> reinforcement learning (RL)

## فصل دوم

### روش‌های مبتنی بر ساختار

روش‌های خلاصه‌سازی مبتنی بر ساختار شامل رویکردهایی است که از ویژگی‌های ساختاری متن ورودی برای تولید خلاصه‌های مختصر و منسجم استفاده می‌کنند. در این رویکرد اطلاعات مهم متن به یک ساختار از پیش تعریف شده داده می‌شود و خلاصه با توجه به ساختار ایجاد می‌شود. در این فصل روش‌های مبتنی بر درخت<sup>۱</sup>، مبتنی بر قالب<sup>۲</sup>، مبتنی بر هستان‌شناسی<sup>۳</sup>، عبارت مقدمه و بدنه<sup>۴</sup>، مبتنی بر گراف<sup>۵</sup> و مبتنی بر قانون<sup>۶</sup> مورد بررسی قرار می‌گیرد.

## ۱-۲ روش مبتنی بر درخت

روش مبتنی بر درخت در خلاصه‌سازی متن شامل استفاده از درخت‌های وابستگی برای نمایش سند متنی است. متن مبدأ ابتدا به درخت‌های وابستگی تبدیل می‌شود، سپس این درخت‌ها در یک درخت واحد ادغام می‌شوند. در نهایت درخت وابستگی ادغام شده به جمله تبدیل می‌شود. فرآیند تبدیل درخت وابستگی به رشته‌ی کلمات را خطی سازی درخت می‌گویند. عملکرد این روش به انتخاب تجزیه‌کننده و حفظ وابستگی بین کلمات بستگی دارد و این باعث محدود شدن کارایی می‌شود. تکنیک‌های پیشنهاد شده شامل استفاده از تجزیه‌کننده‌های کم عمق برای ترکیب جملات مشابه، فشرده‌سازی با استفاده از حذف زیردرخت‌ها، تولید درخت‌های تودرتو با استفاده از ساختارهای بلاغی و تجزیه وابستگی است. [۲۲].

## ۲-۲ روش مبتنی بر قالب

روش‌های مبتنی بر الگو در خلاصه‌سازی متن شامل استفاده از قالب‌های از پیش تعریف شده برای نمایش سند است. این قالب‌ها برای مطابقت با الگوها و قوانین خاص در محتوای متنی طراحی شده‌اند و امکان استخراج اطلاعات مرتبط را فراهم می‌کنند که می‌توان آن‌ها را در فضای قالب ترسیم کرد. این فرآیند شامل تطبیق متن با این الگوها و قوانین برای شناسایی محتوای متناسب با الگو است. این روش بسیار منسجم است زیرا خلاصه‌هایی تولید می‌کند که به ساختار و قالب قالب‌ها پایبند هستند. یکی از چالش‌های روش مبتنی بر الگو، نیاز به تجزیه و تحلیل معنایی دقیق است، زیرا قالب‌ها نیاز به محتوای خاص و مرتبط برای پر شدن دارند [۲۲].

<sup>1</sup>tree-based

<sup>2</sup>template-based

<sup>3</sup>ontology-based

<sup>4</sup>lead-and-body phrase

<sup>5</sup>graph-based

<sup>6</sup>rule-based



## ۳-۲ روش مبتنی بر هستان شناسی

روش مبتنی بر هستی‌شناسی در خلاصه‌سازی متن شامل استفاده از پایگاه دانش یا هستی‌شناسی برای بهبود فرآیند خلاصه‌سازی است. بسیاری از اسناد موجود در اینترنت به حوزه‌های خاصی با واژگان محدود مرتبط هستند که می‌توانند توسط هستی‌شناسی بهتر نمایش داده شوند. هستی‌شناسی نامگذاری و تعریف رسمی انواع موجودیت مربوط به یک دامنه خاص را ارائه می‌دهد که به عنوان پایگاه دانش عمل می‌کند. با استفاده از هستی‌شناسی، سیستم خلاصه‌سازی می‌تواند نمایش معنایی محتوای اطلاعات را بهبود بخشد. تکنیک‌های این روش شامل استفاده از هستی‌شناسی برای ساخت یک مدل معنایی، نگاشت جملات به گره‌های هستی‌شناسی، و محاسبه امتیاز مربوط به موجودیت برای رتبه‌بندی جملات است. به طور کلی، روش مبتنی بر هستی‌شناسی از دانش خاص دامنه برای ایجاد خلاصه‌های دقیق‌تر و آموزنده‌تر استفاده می‌کند [۲۲]. لی و همکاران یک سیستم فازی را ارائه کرد که از هستی‌شناسی طراحی شده توسط متخصص حوزه اخبار استفاده می‌کند. جملات بر اساس طبقه‌بندی کننده اصطلاحی مبتنی بر هستی‌شناسی طبقه‌بندی می‌شوند. مکانیزم استنتاج فازی درجه عضویت برای هر جمله را با توجه به طبقه‌بندی کننده محاسبه می‌کند [۱۳].

## ۴-۲ روش عبارت مقدمه و بدنه

روش عبارت مقدمه و بدنه یک رویکرد خلاصه‌سازی متن است که بر شناسایی و بازنگری جملات اصلی، معروف به جملات کلیدی، در یک سند تمرکز دارد. جملات کلیدی معمولاً حاوی اطلاعات مفید هستند و خلاصه خوبی از محتوا ارائه می‌دهند. این روش شامل درج و جایگزینی عبارات در جمله اصلی برای ایجاد تکرار مناسب با بازبینی‌های معنی‌دار است. محدودیت‌های این روش شامل عدم وجود مدل تعمیم یافته برای خلاصه‌سازی و تاثیر منفی مدل تجزیه دستوری است. [۲۲]. ایشیکاوا و همکاران روش خلاصه‌سازی ترکیبی مبتنی بر روش فرکانس تکرار عبارت<sup>۷</sup> و عبارت مقدمه و بدنه پیشنهاد کردند. تابع توزیع زاویه‌ای ضربدر بسامد عبارت میزان اهمیت هر جمله را مشخص می‌کند. دستورهای براساس اهمیت برای نوشتن خلاصه رتبه‌بندی می‌شوند [۹].

## ۵-۲ روش مبتنی بر گراف

یکی دیگر از رویکردهای خلاصه‌سازی روش مبتنی بر نمودار است که هر جمله در یک سند را به عنوان یک راس در یک نمودار نشان می‌دهد. جملات بر اساس روابط معنایی با یال‌ها به هم متصل می‌شوند و وزن یال‌ها نشان دهنده قدرت رابطه است. سپس از یک الگوریتم رتبه‌بندی نمودار برای تعیین اهمیت هر جمله استفاده می‌شود. جملات با اهمیت بالاتر در خلاصه گنجانده می‌شوند. این روش نیازی به

<sup>7</sup>Term frequency (TF)

دانش عمیق زبانی یا حوزه‌ای ندارد و می‌تواند با انتخاب جملاتی با اهمیت بالا، خلاصه‌های مختصر و منسجم ایجاد کند [۲۲]. مالیروس و اسکینیس از مرکزیت گره برای نشان دادن اهمیت یک اصطلاح در سند استفاده می‌کنند. مرکزیت‌های گره محلی و جهانی برای وزن‌دهی عبارت در نظر گرفته می‌شوند تا خلاصه را شکل دهند [۲۰].

## ۶-۲ روش مبتنی بر قانون

در روش خلاصه سازی مبتنی بر قاعده، اسناد را به دسته بندی ها و جنبه ها تقسیم می کنیم. سپس، ماژولی به نام ماژول انتخاب محتوا، بهترین اطلاعات را براساس قوانین از پیش تعریف شده انتخاب می کند تا به جنبه های هر دسته پاسخ دهد. در نهایت، ما از الگوهای تولید برای ایجاد جملات خلاصه مختصر استفاده می کنیم. بنابراین، اساساً، ما قوانینی داریم که به ما کمک می کنند تا مهم ترین اطلاعات را برای هر جنبه انتخاب کنیم، و سپس از آن قوانین برای تولید یک خلاصه استفاده می کنیم [۲۱].

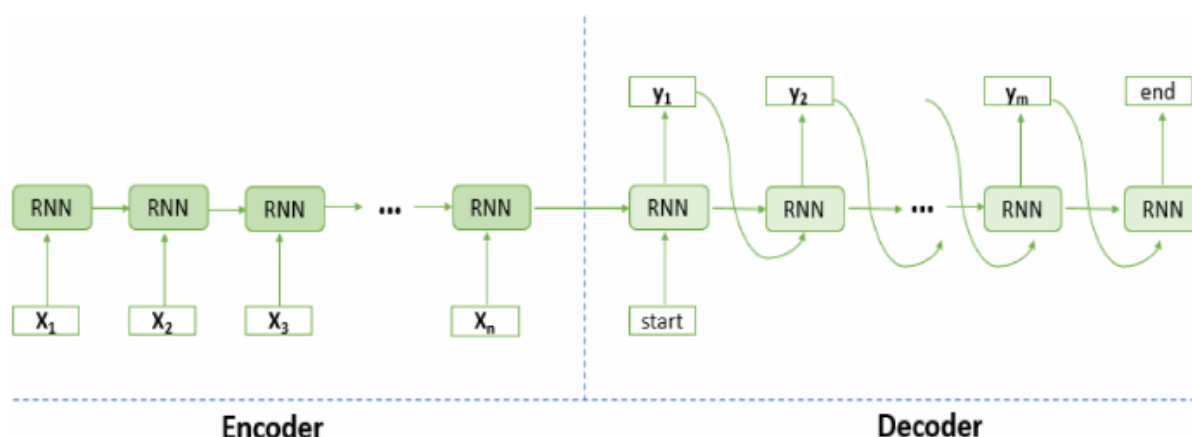
## فصل سوم

### روش‌های مبتنی بر شبکه‌ی عصبی عمیق

هدف خلاصه‌سازی انتزاعی متن تبدیل یک دنباله از کلمات به دنباله‌ای دیگر از کلمات است. پژوهش‌ها نشان داده است که مدل‌های دنباله به دنباله<sup>۱</sup> با استفاده از معماری کدگذار-کدگشا<sup>۲</sup> بهترین انتخاب برای مدل‌سازی وظایف تولید متن هستند. با این حال استفاده از آن‌ها ممکن است منجر به ایجاد خلاصه‌های فاقد اطلاعات مهم با چندین موضوع یا حاوی عبارات تکراری شود. در این بخش ابتدا پژوهش‌های انجام شده در زمینه‌ی رفع مشکلات خلاصه‌سازی انتزاعی متن با استفاده از مدل‌های کدگذار-کدگشا و ترنسفورمر<sup>۳</sup> بررسی می‌شود. سپس به ایده‌های ارائه شده برای حل چالش‌های محاسباتی مرتبط با پردازش دنباله‌های طولانی پرداخته می‌شود.

### ۱-۳ روش‌های مبتنی بر مدل کدگذار-کدگشا

قبل از ظهور ترنسفورمرها، مدل‌های شبکه عصبی عمیق دنباله به دنباله بهترین مدل برای وظایف تولید متن از جمله ترجمه‌ی ماشینی و خلاصه‌سازی متن بوده‌اند. این مدل‌ها ورودی را از یک فرم به فرم دیگر نگاشت می‌کنند تا نتایج مورد نظر را تولید کنند. معماری کدگذار-کدگشا رویکرد اصلی برای مدل‌سازی مدل‌های دنباله به دنباله است. شکل ۱-۳ معماری پایه‌ی مدل کدگذار-کدگشا را شرح می‌دهد. شبکه‌های عصبی بازگشتی<sup>۴</sup> [۴] و حافظه‌های کوتاه مدت طولانی<sup>۵</sup> [۷] برای توالی طراحی شده‌اند و برای کدگذاری و پردازش داده‌های دنباله‌ای مانند متن مناسب هستند اما در مدیریت حافظه‌ی بلند مدت مشکل دارند.



شکل ۱-۳: معماری پایه‌ی مدل کدگذار-کدگشا [۸]

یائو<sup>۶</sup> و همکاران مدل کدگذاری دوگانه را برای خلاصه‌سازی انتزاعی پیشنهاد داده‌اند. این مدل برای

<sup>۱</sup>sequence to sequence

<sup>۲</sup>encoder decoder

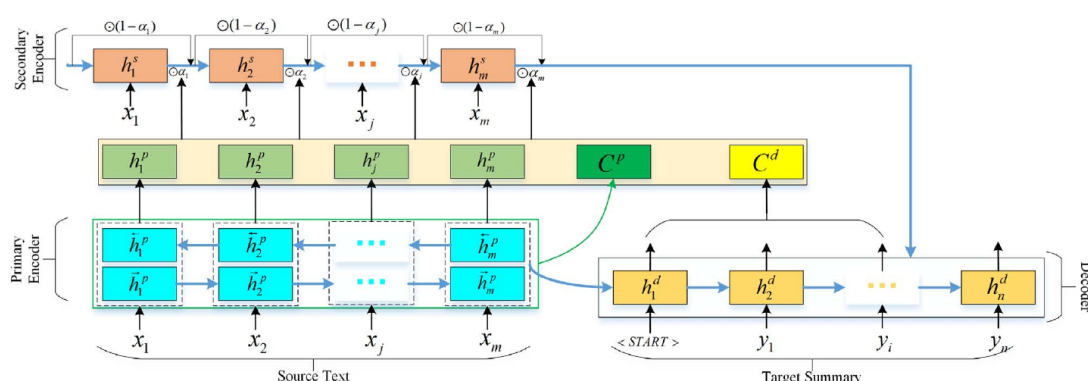
<sup>۳</sup>transformer

<sup>۴</sup>recurrent neural network (RNN)

<sup>۵</sup>long short-term memory networks(LSTM)

<sup>۶</sup>Yao

درک بهتر روابط بین متن ورودی و خلاصه مرجع بازنمایی متن ورودی و بازنمایی خلاصه‌ی مرجع را می‌آموزد. همانطور که در شکل ۲-۳ نشان داده شده است. این مدل از یک کدگذار اولیه، یک کدگذار ثانویه و یک کدگشا مجهز به مکانیزم توجه تشکیل شده است و هر سه ماژول فوق از واحد بازگشتی دروازه‌ای<sup>۷</sup> استفاده می‌کنند. کدگذار اولیه بردارهای معنایی هر کلمه در ترتیب ورودی را محاسبه می‌کند. کدگذار ثانویه وزن اهمیت هر کلمه در ترتیب ورودی و بردارهای معنایی مربوطه را دوباره محاسبه می‌کند. در نهایت کدگشا با مکانیزم توجه به صورت مرحله‌ای کدگشایی می‌کند و در هر مرحله یک توالی خروجی با طول ثابت جزئی ایجاد می‌کند. در این مدل کدگذار ثانویه عملیات کدگذاری را براساس ورودی هر مرحله و خروجی مرحله قبل انجام می‌دهد بنابراین کیفیت متون قبلی تولید شده توسط کدگشا بر خروجی‌های جدید تاثیر می‌گذارد [۳۳].




شکل ۲-۳: معماری پایه‌ی مدل دوگانه‌ی کدگذار [۳۳]

مدل کدگذاری دوگانه مدل سلسله مراتبی متغیر بر اساس مدل کدگذاری دوگانه برای خلاصه‌سازی متقاطع زبانی<sup>۸</sup> پیشنهاد شده است. این مدل شامل دو متغیر نهفته محلی و یک متغیر نهفته جامع است. از متغیرهای نهفته محلی برای بازسازی ترجمه و خلاصه زبان مبدأ و از متغیر نهفته سراسری برای تولید خلاصه بین زبانی استفاده می‌شود. قسمت کدگذار این مدل دو بخش دارد که هر بخش وظیفه‌ی تولید یکی از متغیرهای نهفته محلی را دارد و بخش کدگشا با استفاده از نمایش‌های نهفته‌ی محلی خلاصه‌ی نهایی را تولید می‌کند. ساختار سلسله مراتبی این مدل به آن اجازه می‌دهد تا رابطه سلسله مراتبی بین ترجمه، خلاصه‌سازی و خلاصه‌سازی بین زبانی را بیاموزد [۱۵].

<sup>۷</sup>gated recurrent unit (GRU)

<sup>۸</sup>cross-lingual



شکل ۳-۳: معماری پایه‌ی مدل سلسله‌مراتبی متغیر برای خلاصه‌سازی متقابل زبانی [۱۵]

متغیرهای محلی  $z_{mt}$  و  $z_{ms}$  به ترتیب برای ترجمه و خلاصه‌سازی و متغیر جامع  $z_{cls}$  برای خلاصه‌سازی بین زبانی طراحی شده‌اند. خطوط خاکستری نشان‌دهنده فرآیند آموزشی است که مسئول تولید  $(z'_{cls}, z'_{ms}, z'_{mt})$  از توزیع پسین متناظر پیش‌بینی‌شده توسط شبکه است. خطوط قرمز خط چین نشان‌دهنده فرآیند استنتاج برای تولید نمایش‌های نهفته  $(z_{cls}, z_{ms}, z_{mt})$  از توزیع‌های پیش‌بینی شده توسط شبکه‌های قبلی است.

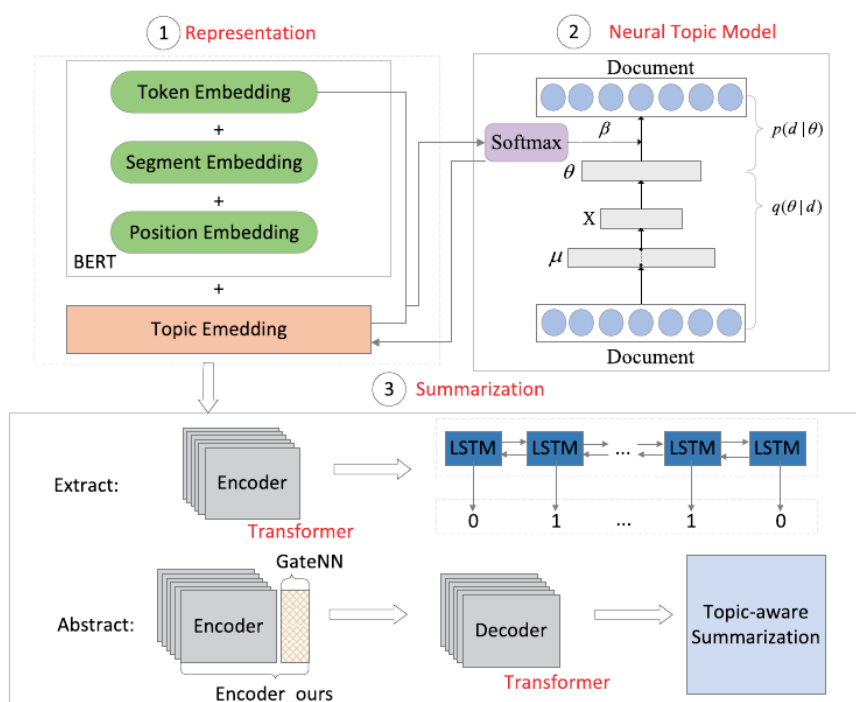
## ۲-۳ روش‌های مبتنی بر مدل ترنسفورمر

با ظهور ترنسفورمرها<sup>۹</sup>، بهبودهای قابل توجهی در کیفیت نتایج خلاصه‌سازی خودکار به وجود آمد. ترنسفورمرها با استفاده از مکانیزم توجه به خود<sup>۱۰</sup> شباهت بین ورودی‌ها را بدون توجه به موقعیت موازی آن‌ها با حضور مستقل هر توکن در توالی ورودی مدل می‌کنند و به طور مؤثر مشکلات شبکه‌های بازگشتی را حل می‌کنند [۳۱]. یکی از جهت‌گیری‌های رایج پژوهشی، اصلاح یا تطبیق ترنسفورمرها و مدل‌های زبانی از پیش آموزش دیده با وظایف مختلف مانند خلاصه‌سازی است. مدل‌های مبتنی بر مدل‌های زبانی از پیش آموزش دیده که با هدف خلاصه‌سازی انتزاعی طراحی شده‌اند از ویژگی‌های معنایی و متنی غنی بازنمایی‌های زبان برای بهبود کیفیت و دقت خلاصه‌ها استفاده می‌کنند.

<sup>۹</sup>transformers

<sup>۱۰</sup>Self-attention

پان<sup>۱۱</sup> و همکاران یک مدل خلاصه‌سازی بر اساس مدل برت را پیشنهاد کرده‌اند. نویسندگان استدلال می‌کنند که خلاصه‌های تولید شده توسط مدل‌های خلاصه‌سازی متن موجود که موضوع متن را در نظر نمی‌گیرند، مرتبط یا حاوی اطلاعات مفید نیستند. مدل ارائه شده که تی‌برت‌سام<sup>۱۲</sup> نامیده می‌شود از سه بخش ایجاد بازنمایی، مدل موضوعی عصبی<sup>۱۳</sup> و مدل خلاصه‌سازی تشکیل شده است. ساختار مدل را در شکل ۳-۴ نشان داده شده است.



شکل ۳-۴: معماری مدل تی‌برت‌سام [۱۹]

همانطور که در شکل ۳-۵ نشان داده شده است، بازنمایی ایجاد شده برای هر جمله ورودی، با استفاده از یک شبکه‌ی ترنسفورمر دوسویه‌ی<sup>۱۴</sup> چند لایه و حاصل جمع چهار نوع تعبیه (تعبیه نشانه<sup>۱۵</sup>، تعبیه قطعه<sup>۱۶</sup>، تعبیه موقعیت و تعبیه موضوع) به دست می‌آید که تعبیه موضوع در این مقاله معرفی شده و سه تعبیه دیگر مشابه مدل برت هستند. وجود تعبیه موضوع در تولید بازنمایی هر کلمه یا جمله موجب افزودن اطلاعات پیش زمینه‌ای به هر کلمه و حل مشکل چند معنایی می‌شود. مدل موضوعی عصبی وظیفه‌ی ایجاد تعبیه موضوعی را دارد. این مدل دارای دو جزء است: یک

<sup>11</sup>Pan

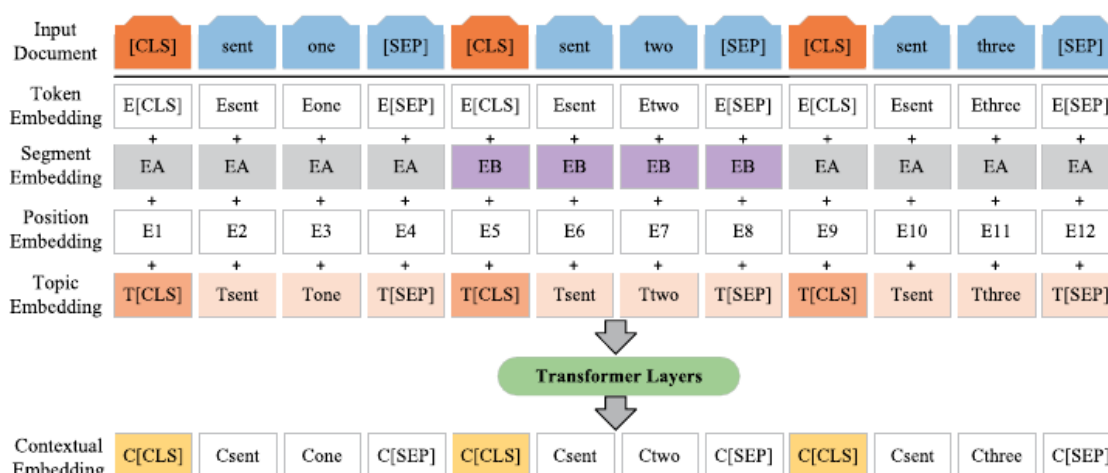
<sup>12</sup>T-BERTSum

<sup>13</sup>Neural Topic Model (NTM)

<sup>14</sup>bidirectional

<sup>15</sup>token embedding

<sup>16</sup>segment embedding



شکل ۳-۵: تعبیه مدل تی‌برت‌سام [۱۹]

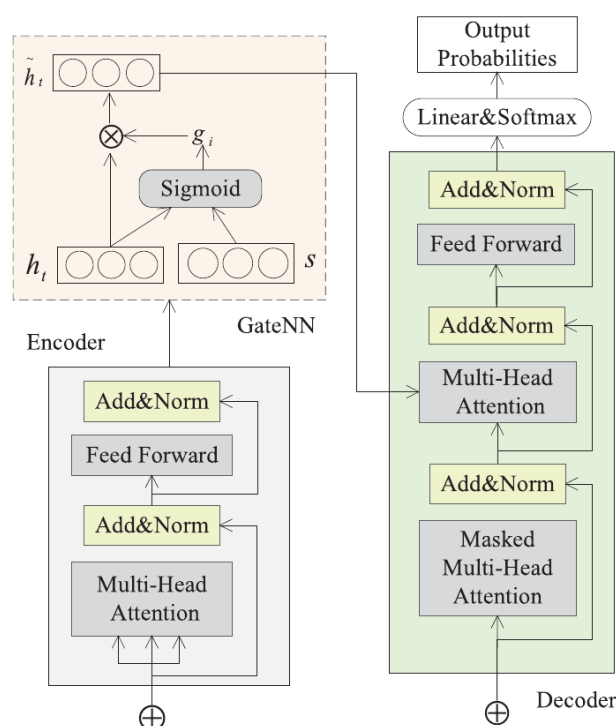
شبکه مولد و یک شبکه استنتاج. شبکه مولد یک سند را به عنوان ورودی می‌گیرد و یک توزیع موضوعی را بر روی کلمات موجود در سند خروجی می‌دهد. شبکه استنتاج یک سند را به عنوان ورودی می‌گیرد و خروجی آن پارامترهای توزیع موضوع است. بخش خلاصه‌سازی مدل مبتنی بر معماری کدگذار - کدگشای ترنسفورمر است. کدگذار بازنمایی ایجاد شده را به عنوان ورودی می‌گیرد و دنباله‌ای از حالت‌های پنهان را تولید می‌کند. سپس کدگشا با استفاده از حالت‌های پنهان و متن خلاصه را تولید می‌کند. همانطور که در شکل ۳-۶ نشان داده شده است، به منظور فیلتر کردن اطلاعات کلیدی توالی ورودی، شبکه دروازه‌ای قبل از کدگشا اضافه می‌شود. این شبکه برای کنترل جریان اطلاعات از دنباله ورودی به دنباله خروجی افزوده شده است و باعث می‌شود کدگشا بر روی تولید خلاصه از اطلاعات کلیدی و حذف اطلاعات غیرضروری تمرکز کند. این مدل می‌تواند خلاصه‌هایی تولید کند که مرتبط با موضوع متن و حاوی اطلاعات مفید باشد و قابلیت تطبیق با حوزه‌های مختلف را دارد.

اکثر مدل‌های خلاصه‌سازی انتزاعی موجود برای تولید خلاصه‌های با طول ثابت طراحی شده‌اند، بنابراین سو<sup>۱۷</sup> و همکاران یک مدل دو مرحله‌ای مبتنی بر ترنسفورمر ارائه دادند که خلاصه‌های انتزاعی با طول متغیر را با توجه به تقاضای کاربر تولید کند. مطابق شکل ۳-۷ مدل پیشنهادی با تقسیم متن ورودی به بخش‌ها، استخراج اطلاعات کلیدی و تولید خلاصه‌ی هر بخش، خلاصه‌ی انتزاعی با طول متغیر تولید می‌کند [۳۰]. بخش‌های مدل ارائه شده به شرح زیر است.

- بخش‌بندی متن: این مرحله متن ورودی را به تعدادی قسمت از پیش تعیین شده تقسیم می‌کند. تعداد بخش‌ها را می‌تواند توسط کاربر مشخص شود یا با توجه به نسبت دلخواه طول ورودی تنظیم کرد. برای شناسایی مرزهای بین بخش‌ها از مدل *BERT – biLSTM* استفاده می‌شود. این مرحله تضمین می‌کند که مرحله خلاصه‌سازی انتزاعی بر روی بخش‌های منسجم متن انجام

<sup>17</sup>Ming-Hsiang Su





شکل ۳-۶: معماری ترنسفورمر تی‌برت‌سام [۱۹]

این مدل شامل شبکه‌ی دروازه‌ای و کدگذار-کدگشا با توجه چند سر می‌باشد [۱۹]

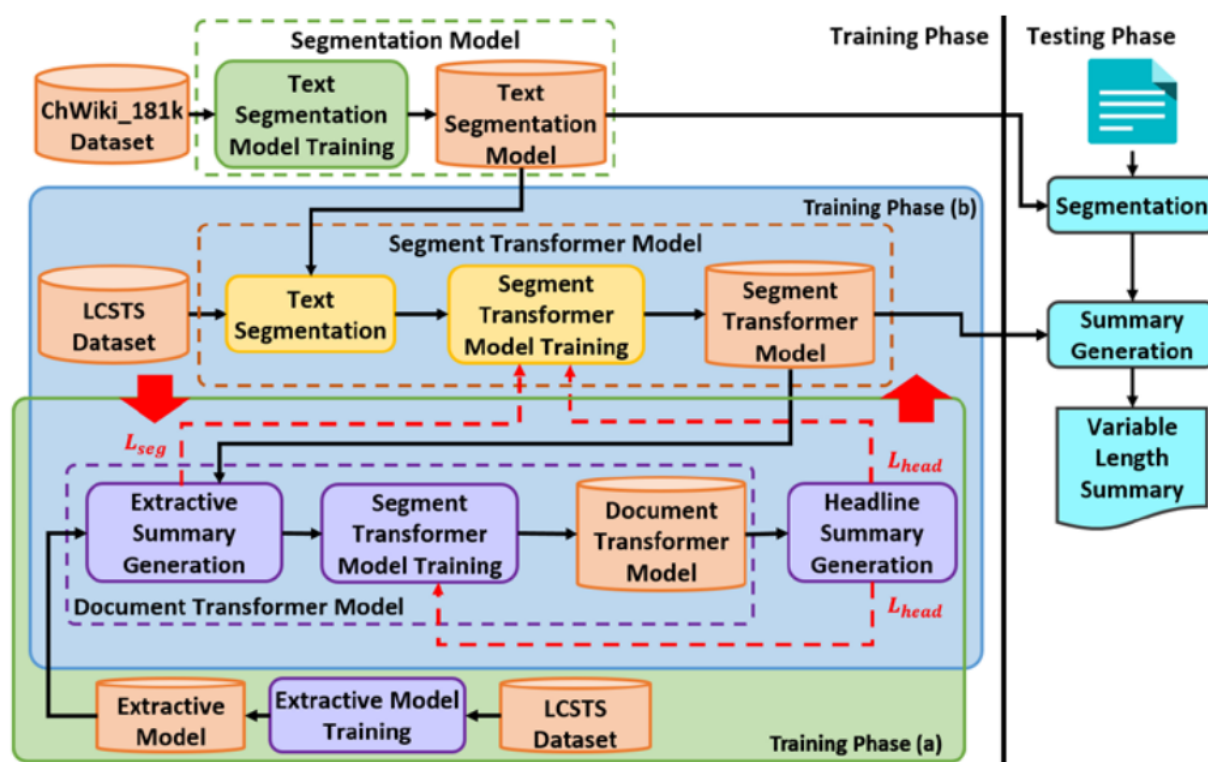
می‌شود. هدف این بخش یافتن نقاط تقسیم‌بندی است که نشان دهنده تغییر موضوع در متن است و به بهبود کیفیت خلاصه‌های تولید شده کمک می‌کند.

- خلاصه‌سازی استخراجی: پس از تقسیم‌بندی متن، با استفاده از یک مدل خلاصه‌سازی استخراجی مبتنی بر برت‌سام<sup>۱۸</sup> مهم‌ترین جمله را از هر بخش استخراج می‌شود.
- خلاصه‌سازی اسناد: با استفاده از جملات استخراج شده این ماژول خلاصه سرفصل سند ورودی را تولید می‌کند که این خلاصه به عنوان خروجی هدف در مرحله آموزش مدل دو مرحله‌ای استفاده می‌شود. مدل ترنسفورمر سند به حل مشکل تغییر طول ورودی و خروجی در کار خلاصه‌سازی کمک می‌کند.
- خلاصه‌سازی بخش: این ماژول وظیفه‌ی تولید خلاصه برای بخش‌های به دست آمده از مرحله تقسیم‌بندی متن را دارد.
- آموزش مشارکتی: برای آموزش متناوب ماژول خلاصه‌سازی بخش و ماژول خلاصه‌سازی اسناد تا زمان همگرایی آموزش مشارکتی اعمال می‌شود. این فرآیند به بهینه سازی عملکرد هر دو ماژول کمک می‌کند.

<sup>18</sup>BertSum

- ایجاد خلاصه با طول متغیر: پس از اینکه متن ورودی به بخش‌های مختلف تقسیم شد، هر بخش از مازول خلاصه‌سازی بخش عبور می‌کند تا یک خلاصه انتزاعی مبتنی بر جمله ایجاد کند. سپس این خلاصه‌های مبتنی بر جمله به هم متصل می‌شوند تا خلاصه انتزاعی با طول متغیر را تشکیل دهند. این فرآیند الحاق تضمین می‌کند که خلاصه تولید شده شامل اطلاعات تمام بخش‌های متن ورودی است.

با ترکیب روش‌های استخراجی و انتزاعی در مدل خلاصه‌سازی دو مرحله‌ای، رویکرد پیشنهادی می‌تواند خلاصه‌های انتزاعی روان و با طول متغیر را با توجه به خواسته‌های کاربر تولید کند [۳۰].



شکل ۳-۷: چهارچوب ایجاد خلاصه با طول متغیر [۳۰]

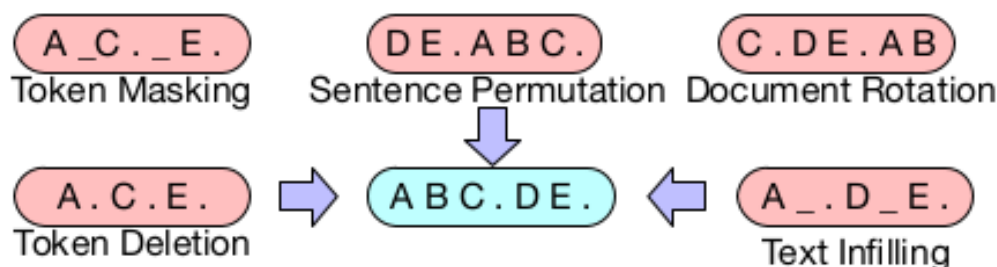
لوئیس و همکاران مدلی با نام بارت<sup>۱۹</sup> ارائه دادند. این مدل مشابه با مدل اصلی ترنسفورمر، ساختاری کدگذار-کدگشا دارد. بر خلاف سادگی، به دلیل داشتن کدگذار دو طرفه و کدگشای چپ به راست این مدل را می‌توان نسخه عمومی‌تری از برت و جی‌پی‌تی<sup>۲۰</sup> دانست. بارت در عملیات تولید متن، مانند ترجمه ماشینی یا خلاصه‌سازی انتزاعی متن، و همچنین در فهم متن کاربرد دارد و با استفاده از اهداف کدگذاری خودکار حذف نویز آموزش می‌بیند. برای پیش‌آموزش بارت نواقصی در سندهای ورودی ایجاد می‌شود و با بهینه کردن تابع زیان آنتروپی-مقاطع<sup>۲۱</sup> بین خروجی‌های کدگشا و سند اولیه، متن بازسازی

<sup>۱۹</sup>BART

<sup>۲۰</sup>GPT

<sup>۲۱</sup>cross-entropy

می‌شود. همانطور که در شکل ۳-۸ نشان داده شده است این مدل طیف گسترده‌ای از نویزها از جمله پوشاندن توکن، حذف توکن، پر کردن متن، چرخش سند، به هم ریختن جمله (به هم زدن تصادفی ترتیب کلمه یک جمله) را استفاده می‌کند [۱۴].



شکل ۳-۸: عمل‌های پیش‌آموزش بارت [۱۴]

با این که بارت دقت خلاصه‌سازی انتزاعی متن را بهبود بخشید، ولی مراحل پیش‌آموزش آن، مختص خلاصه‌سازی انتزاعی متن نیستند، در نتیجه در سال ۲۰۲۰ مدلی تحت عنوان پگاسوس<sup>۲۲</sup> توسط ژنگ و همکاران ارائه شد که معماری مشابه با بارت داشت ولی پیش‌آموزش آن مختص خلاصه‌سازی انتزاعی متن بود. مدل پگاسوس یک مدل دنباله به دنباله کدگذار کدگشا مبتنی بر ترنسفورمر است که بر روی مجموعه‌های متنی بدون نظارت با هدف تولید جملات فاصله‌افتاده<sup>۲۳</sup> از قبل آموزش داده شده است [۳۵]. این مدل دو روش پیش‌آموزش را معرفی کرده است که در ادامه به شرح آنها می‌پردازیم:

۱. تولید جملات فاصله‌افتاده: فرضی مطرح شده است که اگر عمل پیش‌آموزش مدل به وظایف پایین‌دست<sup>۲۴</sup> نزدیک‌تر باشد، نتیجه نهایی به‌تر و همچنین تنظیم دقیق پارامترها<sup>۲۵</sup> سریع‌تر خواهد بود. با توجه به این که این مدل قرار است فقط برای خلاصه‌سازی انتزاعی متن استفاده شود، عمل پیش‌آموزش مشابه تولید متن‌های خلاصه از یک سند ورودی تعریف شده است. تعدادی از جملات انتخاب شده و هر جمله به طور کامل با توکن  $[MASK1]$  جایگزین می‌شود. برای انتخاب این جملات، سه راه پیشنهاد شده است.

- انتخاب تصادفی: جمله  $m$  به صورت تصادفی از متن انتخاب شده و پنهان می‌شوند.
- انتخاب جملات اول متن: جمله اول متن پنهان می‌شوند زیرا اغلب جملات ابتدای متن نسبت به جملات بعدی مهم‌تر هستند.
- انتخاب جملات مهم متن: برای انتخاب  $m$  جمله مهم متن از تقریب معیار ارزیابی روژ-۱ استفاده می‌شود. به ازای هر جمله از متن، یک دوتایی از آن جمله و متن سند فاقد آن

<sup>۲۲</sup>PEGASUS

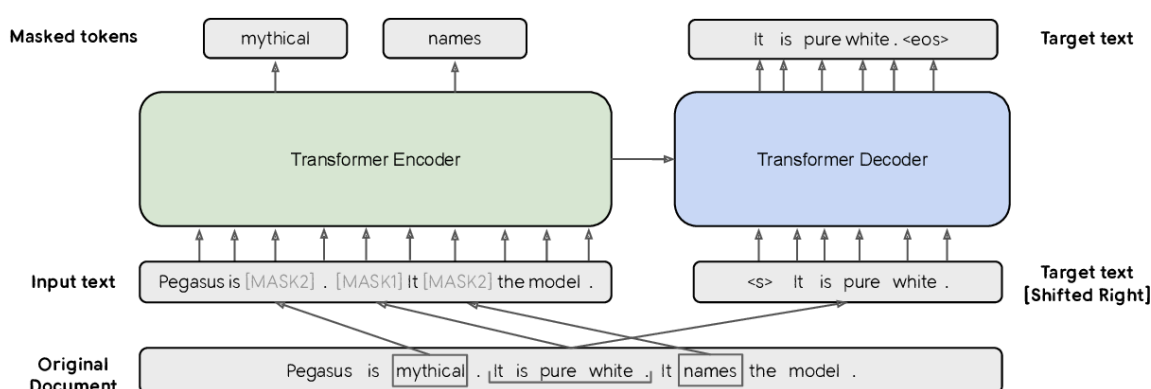
<sup>۲۳</sup>gap sentences generation

<sup>۲۴</sup>downstream task

<sup>۲۵</sup>fine-tuning

جمله ساخته شده و ارزیابی می‌شود که چقدر ممکن است این جمله، خلاصه سند فاقد آن جمله باشد. جملاتی که امتیاز بالاتر گرفته‌اند از نظر خلاصه بودن مهم‌تر هستند و پنهان می‌شوند.

۲. مدل زبانی پوشیده شده: مشابه مدل برت ۵۱ درصد از توکن‌های متن ورودی انتخاب می‌شوند و سپس ۸۰ درصد از این توکن‌ها، با توکن  $[MASK2]$  و ۱۰ درصد توکن‌ها با یک توکن تصادفی جایگزین می‌شوند. ۱۰ درصد دیگر بدون تغییر باقی می‌ماند. شکل ۳-۹ اعمال همزمان این دو عمل، یعنی تولید جمالت فاصله افتاده و مدل زبانی پوشیده شده را بر روی یک ورودی نشان می‌دهد.



شکل ۳-۹: ساختار مدل پگاسوس [۳۵]

معماری پایه پگاسوس یک کدگذار-کدگشا ترنسفورمر استاندارد است. جملات فاصله‌افتاده و مدل زبانی پوشیده شده به طور همزمان در این مثال به عنوان اهداف پیش‌آموزش اعمال می‌شوند. در اصل سه جمله وجود دارد. یک جمله با  $[MASK1]$  پوشانده شده و به عنوان متن تولید هدف جملات فاصله‌افتاده استفاده می‌شود. دو جمله دیگر در ورودی باقی می‌مانند و برخی از نشانه‌ها به طور تصادفی توسط  $[MASK2]$  پوشانده می‌شوند [۳۵].


کدیا<sup>۲۶</sup> و همکاران الگوریتم حداکثرسازی نقطه-محصول فرایادگیری (امدات)<sup>۲۷</sup> را برای بهبود پگاسوس پیشنهاد دادند. این الگوریتم بر اساس ایده به حداکثر رساندن حاصل ضرب نقطه‌ای بین گرادین‌های مدل در نقاط مختلف آموزش با استفاده از تکنیکی به نام تفاوت‌های محدود<sup>۲۸</sup> است. این الگوریتم از نظر محاسباتی کارآمد است و می‌تواند برای مدل‌های بزرگ مانند برت اعمال شود و سربار محاسباتی را کاهش بدهد [۲۸]. عملکرد مناسب مدل پگاسوس در خلاصه‌سازی متون باعث شده بهترین مدل خلاصه‌سازی متون کوتاه مبتنی بر مدل پگاسوس و تکنیک تنظیم<sup>۲۹</sup> امدات باشد.

<sup>26</sup>Kedia

<sup>27</sup>Meta-Learned Dot-Product Maximization (MDot)

<sup>28</sup>finite differences

<sup>29</sup>regularization



شکل ۳-۱۰: الگوریتم امدات [۲۸]

محاسبه گرادیان برای به حداکثر رساندن محصول نقطه‌ای با استفاده از تقریب تفاضل محدود و استفاده از آن برای تنظیم گرادیان استاندارد [۲۸].

### ۳-۲-۱ ایده‌های ارائه شده بهبود خلاصه‌سازی متون طولانی

یکی از مشکلات مدل ترنسفورمر در خلاصه‌سازی متون طولانی، حافظه‌ی درجه دوم، پیچیدگی‌های محاسباتی و تعداد زیاد عملیات می‌باشد. برای حل این چالش‌ها ایده‌های مختلفی ارائه شده است. به عنوان مثال شبکه‌ی ریفورمر<sup>۳۰</sup> برای حل چالش‌های محاسباتی مرتبط با پردازش دنباله‌های طولانی متن ارائه شده است. لایه‌های برگشت‌پذیر<sup>۳۱</sup> معرفی شده در این مقاله امکان بازسازی ورودی از خروجی را در طول گذر به عقب را فراهم می‌کنند که موجب کاهش نیازهای حافظه و امکان پردازش کارآمد دنباله‌های طولانی می‌شود. علاوه بر این، ریفورمر از تکه تکه کردن برای پردازش بخش‌های کوچک‌تر ورودی به طور مستقل استفاده می‌کند که موازی‌سازی را ممکن می‌کند و مصرف حافظه را کاهش می‌دهد. همچنین استفاده از درهم‌سازی حساس به مکان<sup>۳۲</sup> در مکانیسم توجه منجر به محاسبه توجه کارآمدتر می‌شود. درهم‌سازی حساس به مکان با توجه به زیرمجموعه‌ای از نشانه‌ها بر اساس مقادیر هش آنها، محاسبه توجه کامل را تقریب می‌زند. علاوه بر این، ریفورمر از کدگذاری‌های موقعیت محوری برای کدگذاری اطلاعات موقعیت توکن‌ها به صورت فشرده استفاده می‌کند. این تکنیک‌ها مجموعاً مدل ریفورمر را مقیاس‌پذیر می‌سازد، و آن را قادر می‌سازد تا دنباله‌های طولانی متن را مدیریت کند و در عین حال عملکرد رقابتی را در وظایف مختلف پردازش زبان طبیعی حفظ کند [۱۱].

شبکه‌ی ترنسفورمر پراکنده<sup>۳۳</sup> با معرفی فاکتورسازی ماتریس پراکنده‌ی توجه، زمان و حافظه مورد نیاز را به کاهش می‌دهد. با استفاده از پراکندگی، مدل می‌تواند تنها به زیرمجموعه‌ای از نشانه‌های ورودی توجه کند و روی مرتبط‌ترین اطلاعات تمرکز کند و بقیه را نادیده بگیرد. این رویکرد پیچیدگی

<sup>30</sup>Reformer

<sup>31</sup>reversible layers

<sup>32</sup>locality-sensitive hashing (LSH)

<sup>33</sup>sparse

محاسباتی را کاهش می‌دهد و مدل می‌تواند توالی‌های طولانی را مدیریت کند [۲]. مشابه شبکه‌ی ترنسفورمر پراکنده مدل بیگ‌برد که <sup>۳۴</sup> با استفاده از مکانیزم توجه پراکنده <sup>۳۵</sup> عملکرد ترنسفورمر را در مواجهه با دنباله‌ی کلمات طولانی بهبود می‌بخشد، نوآوری‌های دیگری مانند توجه جامع <sup>۳۶</sup> را معرفی می‌کند. در این مدل توکن‌های خاص به تمام توکن‌های دیگر در دنباله توجه می‌کنند و وابستگی‌های دوربرد را بهتر از سایر روش‌ها به دست می‌آورند. همچنین فرآیند پالایش تکراری وزن‌های توجه را برای بهبود عملکرد مدل اصلاح می‌کند [۳۴].

در سال‌های اخیر ایده‌های مختلفی برای بهبود کیفیت خروجی مدل خلاصه‌سازی خودکار اسناد بلند ارائه شده است. به عنوان مثال پایل <sup>۳۷</sup> و همکاران که برای بهبود خلاصه انتزاعی نهایی متون طولانی از رویکرد ترکیبی استخراجی-انتزاعی با استفاده از مدل زبانی از پیش آموزش دیده جی‌پی‌تی-دو <sup>۳۸</sup> استفاده می‌کنند. در این مدل مرحله استخراج ساده قبل از تولید خلاصه انجام می‌شود، سپس برای شرطی کردن مدل زبانی ترنسفورمر بر روی اطلاعات مربوط قبل از تولید خلاصه استفاده می‌شود. این رویکرد در مقایسه با کارهای قبلی که از مکانیزم کپی استفاده می‌کنند، خلاصه‌های انتزاعی بیشتری تولید می‌کند [۲۵]. پانگ <sup>۳۹</sup> و همکاران یک ساختار سلسله مراتبی برای اسناد طولانی فرض کرده‌اند. در این ساختار سطح بالا بر وابستگی دوربرد تمرکز می‌کند و سطح پایین جزئیات را حفظ می‌کند. در استنتاج از پایین به بالا، تعبیه‌های متنی نشانه‌ها با استفاده از توجه محلی محاسبه می‌شوند و برای دریافت وابستگی‌های دوربرد و زمینه جامع، استنتاج از بالا به پایین برای نمایش‌های توکن اعمال می‌شود. یک ساختار پنهان چند مقیاسی دو سطحی استفاده می‌شود، که در آن سطح پایین شامل نمایش‌های نشانه‌ای است که توسط استنتاج پایین به بالا محاسبه می‌شود، سپس با اعمال مکانیزم توجه به سطوح بزرگ‌تر روابط بین بخش‌های مختلف سند را بدست می‌آورد. ساختار مدل را در شکل ۳-۱۱ نشان داده شده است. روش پیشنهادی یک رویکرد جدید امیدوارکننده برای خلاصه‌سازی اسناد طولانی است و نسبت به روش‌های قبلی کارآمدتر و موثرتر است [۲۳].

جید یوتیس و همکاران شیوه‌ی تقسیم و غلبه (دنسر) <sup>۴۰</sup> را برای بهبود خلاصه‌سازی اسناد طولانی پیشنهاد کرده‌اند. این روش به طور خودکار خلاصه یک سند را به چند بخش تقسیم می‌کند و هر یک از این بخش‌ها را به بخش مناسب سند جفت می‌کند تا خلاصه‌های هدف متمایز ایجاد کند. شیوه‌ی معرفی شده در نظر می‌گیرد که متون طولانی به صورت بخش‌های گسسته ساختار بندی شده‌اند. برای مطابقت هر قسمت از خلاصه با بخشی از سند در دنسر از معیار روژ <sup>۴۱</sup> استفاده می‌شود. در این روش معیار روژ-ال بین هر یک از جملات خلاصه و تمام جملات سند محاسبه می‌شود و هر جمله‌ی

<sup>34</sup> Big Bird

<sup>35</sup> Sparse attention

<sup>36</sup> global attention

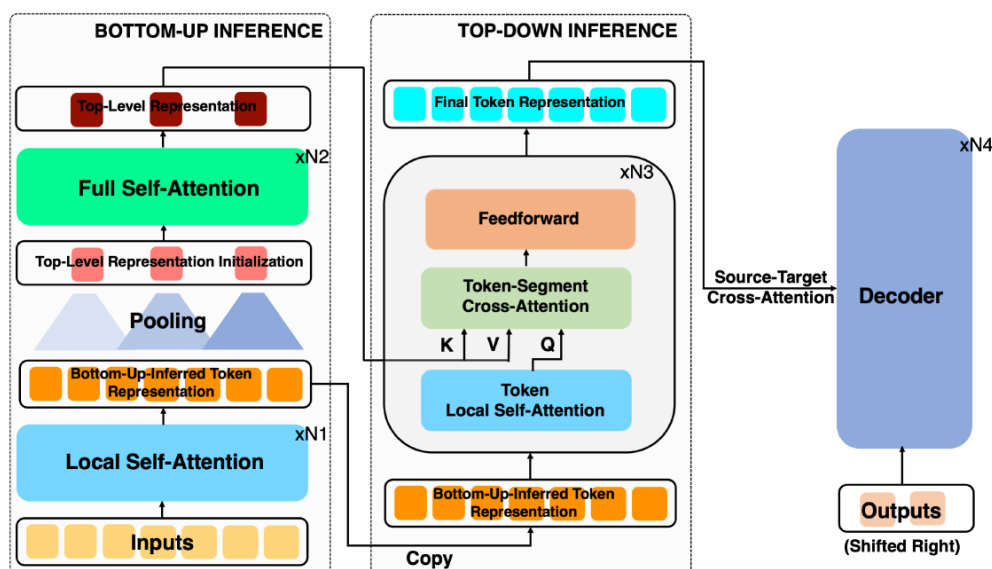
<sup>37</sup> Pilault

<sup>38</sup> GPT-2

<sup>39</sup> Pang

<sup>40</sup> Divide-and-Conquer (DANCER)

<sup>41</sup> ROUGE



شکل ۳-۱۱: معماری مدل ترنسفورمر از بالا به پایین [۲۳]

خلاصه هدف به بخش حاوی جمله با بیشترین روژ-ال نسبت داده می‌شود. سپس تمام جملات خلاصه‌ی هدف مربوط به هر بخش را به هم الحاق می‌کنیم تا خلاصه‌ی هدف برای هر بخش ایجاد شود. در طول آموزش هر بخش از سند به همراه جمله‌ی خلاصه‌ی مربوط به آن به عنوان متن ورودی و خلاصه‌ی هدف استفاده می‌شود. مزایای این روش آموزش:

۱. تقسیم مساله به چند زیر مساله باعث کاهش پیچیدگی و ساده‌سازی مساله می‌شود.
۲. انتخاب خلاصه‌های هدف برای هر بخش بر اساس امتیازات روژ-ال هر جمله باعث تطابق بهتر و متمرکزتر بین دنباله‌های منبع و هدف ایجاد می‌شود.
۳. تقسیم هر سند آموزشی به چند جفت ورودی-هدف، نمونه‌های آموزشی بسیار بیشتری ایجاد می‌کند. این کار برای مدل‌های خلاصه‌سازی عصبی مفید است.
۴. این روش می‌تواند از مدل‌های خلاصه‌سازی مختلف از جمله شبکه‌ی عصبی بازگشتی و ترنسفورمرها استفاده کند.

هنگام کار با اسناد ساختاریافته طولانی، معمولاً همه بخش‌های سند کلیدی برای سند نیستند. اگر یک مقاله آکادمیک را به عنوان مثال در نظر بگیریم، بخش‌هایی مانند مرور ادبیات یا پیشینه در تلاش برای خلاصه کردن نکات اصلی مقاله ضروری نیستند و باعث افزودن نویز می‌شوند. بنابراین از بخش مرور ادبیات صرف نظر می‌شود و تمرکز سیستم خلاصه‌سازی فقط روی بخش‌های مقدمه، روش‌ها، نتایج و نتیجه‌گیری می‌باشد.

این مدل قابل ترکیب با پگاسوس یا مدل مولد نقطه‌ای<sup>۴۲</sup> می‌باشد. بخش کدگشا مدل مولد نقطه‌ای با ایجاد جملات تکراری مقابله می‌کند. هرچند ممکن است به خاطر تکرار اطلاعات در بخش‌های مختلف بازهم خلاصه‌ی تکراری ایجاد شود.

شیونگ و همکاران با اصلاح هدف بهینه‌سازی، معماری مدل‌های از پیش آموزش دیده و مجموعه‌ی دادگان پیش‌آموزش<sup>۴۳</sup> روشی را برای ساخت مدل‌های مناسب متون طولانی پیشنهاد می‌کنند. مدل‌های پیش‌آموزش دیده متن به متن، مانند برت و بارت، معمولاً بر روی دنباله‌های متن کوتاه، مانند جملات یا پاراگراف‌ها آموزش داده می‌شوند. در حالی که بسیاری از وظایف پردازش زبان طبیعی، مانند پاسخگویی به سؤال و خلاصه کردن، به توانایی پردازش توالی متن طولانی نیاز دارند این مقاله تعدادی از تکنیک‌ها را برای تطبیق مدل‌های متن به متن از پیش آموزش دیده برای دنباله‌های متن طولانی پیشنهاد می‌کند. این تکنیک‌ها عبارتند از:

- ارائه‌ی مدل براساس یک ترنسفورمر با مکانیزم توجه به خود پراکنده‌ی بلوکی<sup>۴۴</sup> در قسمت کدگذار است. این مکانیزم امکان استفاده‌ی مجدد از وزن‌های مدل‌های از پیش آموزش دیده را فراهم می‌کند.
- مکانیزم توکن سراسری<sup>۴۵</sup>: در این مکانیزم یک مجموعه‌ی کوچک از توکن‌های سراسری به کل توالی توجه می‌کنند و امکان تعاملات دوربرد در کدگذار فراهم می‌شود.
- هم‌پوشانی بلوک‌های توجه<sup>۴۶</sup>: توجه لغزشی با هم‌پوشانی یک راه ساده برای معرفی اتصالات دوربرد در مدل‌های توجه محلی است. در این رویکرد، توکن‌های درون هر بلوک به تمام توکن‌های درون خود بلوک و همچنین نیمی از توکن‌های بلوک‌های چپ و راست مجاور نزدیک می‌شوند. این نسخه بلوکی از پنجره‌های توجه هم‌پوشانی، راه ساده‌تر و کارآمدتری را برای معرفی اتصالات دوربرد ارائه می‌کند و در عین حال موازی‌سازی را در پیاده‌سازی مدل تسهیل می‌کند.
- لایه‌ی خود توجه مبتنی بر ادغام بلوکی تقویت شده<sup>۴۷</sup>: این لایه به عنوان جایگزین لایه خود توجهی برای اتصالات دوربرد معرفی شده است. این رویکرد به واحدهای توجه درون بلوک‌ها اجازه می‌دهد تا به جای توجه به همسایگان بلافاصل خود، بر خلاصه‌ای از اطلاعات کلی در بلوک‌ها تمرکز کنند. این لایه در تصویر ۳-۱۲ نشان داده شده است. این مدل را قادر می‌سازد تا از اطلاعات گسترده تری در سراسر سند برای تصمیم‌گیری استفاده کند و وابستگی‌های دوربرد را در نظر بگیرد. با بکارگیری عملیات ادغام، ابعاد و نمایش بردارهای توجه کاهش می‌یابد که منجر به افزایش سرعت و کارایی مدل می‌شود.

<sup>42</sup>Pointer-Generator model

<sup>43</sup>pretraining corpus

<sup>44</sup>Block-sparse self-attention


<sup>45</sup>Global-token mechanism

<sup>46</sup>Overlapping attention windows

<sup>47</sup>Pooling-augmented blockwise attention



نویسندگان تکنیک‌های پیشنهادی را در تعدادی از وظایف توالی متن طولانی، از جمله پاسخ‌گویی به سؤال و خلاصه‌نویسی، ارزیابی کرده‌اند. نتایج نشان می‌دهد که مدل‌های اقتباس‌شده در تمامی وظایف از مدل‌های پایه بهتر عمل می‌کنند. این تکنیک‌ها استفاده از مدل‌های متنی از پیش آموزش دیده را برای طیف وسیعی از وظایف پردازش زبان طبیعی ممکن می‌سازد [۳۲].



شکل ۳-۱۲: لایه خودتوجهی تقویت شده ادغام شده [۳۲]

## فصل چهارم

### روش‌های مبتنی بر یادگیری تقویتی

کارهای تحقیقاتی در زمینه یادگیری تقویتی<sup>۱</sup> و پردازش زبان طبیعی در سال‌های اخیر رشد کرده است. در یادگیری تقویتی یک عامل با محیط تعامل می‌کند و با آزمون و خطا، خط مشی بهینه را برای تصمیم‌گیری متوالی برای به حداکثر رساندن پاداش تجمعی آینده می‌آموزد. این پاداش می‌تواند یک معیار تعریف شده توسط توسعه دهنده بر اساس کار در حال حل باشد. در خلاصه‌سازی خودکار انتزاعی متن، نمونه‌هایی از چنین پاداش‌هایی ممکن است شامل حفظ برجستگی، مستلزم منطقی هدایت‌شده، و غیر افزونگی باشد. به طور کلی، یادگیری تقویتی در چهار حوزه مختلف برای بهبود خلاصه‌سازی خودکار استفاده می‌شود:

## ۴-۱ یادگیری تقویتی برای حل مسائل عمیق توالی به دنباله

استفاده از یادگیری تقویتی به منظور حل مسائل گوناگونی که مدل‌های دنباله به دنباله عمیق قادر به حل آن‌ها نیستند، امکانات بیشتری را فراهم می‌کند. به عنوان مثال، مشکلاتی مانند کمبود نوآوری در ایجاد خلاصه‌های خلاقانه و آموزنده و کاهش کیفیت خلاصه‌ها در صورت افزایش طول مقالات منبع، با استفاده از سیستم‌های یادگیری تقویتی و یادگیری خط‌مشی<sup>۲</sup> بهبود یافته است. علاوه بر این مدل‌های دنباله به دنباله عمیق را نمی‌توان برای خلاصه کردن طیف گسترده‌ای از اسناد استفاده کرد، زیرا مدلی که بر روی یک مجموعه داده آموزش داده می‌شود، در یک مجموعه داده دیگر به خوبی عمل نمی‌کند و قابلیت تعمیم ندارد. رویکردهای مبتنی بر یادگیری تقویتی می‌تواند این مشکل را با استفاده از گرادینت خط‌مشی انتقادی<sup>۳</sup> و ترکیب آن با یادگیری انتقالی<sup>۴</sup> برای انتقال دانش از یک مجموعه داده به مجموعه دیگر برطرف کنند [۱۰].

فریم‌ورک پوبرل<sup>۵</sup> (ترکیب سیاست‌ها با حداکثر ارتباط حاشیه‌ای و یادگیری تقویتی) اهمیت، ارتباط و طول خلاصه را در زمینه خلاصه‌سازی چند سندی با جدا کردن مسئله بهینه‌سازی چند هدفه به مسائل فرعی کوچک‌تر که با استفاده از یادگیری تقویتی قابل حل هستند، بهینه می‌کند. اهمیت، ارتباط و طول خلاصه را در زمینه خلاصه‌سازی چند سندی با جدا کردن مسئله بهینه‌سازی چند هدفه به مسائل فرعی کوچک‌تر که قابل حل هستند، بهینه می‌کند. این فریم‌ورک از الگوریتم حداکثر ارتباط حاشیه‌ای<sup>۶</sup> برای استخراج اطلاعات مهم از اسناد استفاده می‌کند. استفاده از این الگوریتم باعث افزایش ارتباط بین جملات و کاهش افزونگی می‌شود. در ادامه با از یادگیری تقویتی رای بهینه‌سازی هر هدف به صورت جداگانه استفاده می‌کند و خط‌مشی‌های جداگانه‌ای را برای اهمیت، ارتباط و طول می‌آموزد [۲۹]. خلاصه‌سازی چند سندی شامل سر و کار داشتن با اطلاعات پیچیده و همپوشانی از منابع متعدد است. الگوریتم‌های یادگیری تقویتی می‌توانند با مدل‌سازی خلاصه‌سازی به عنوان یک فرآیند تصمیم‌گیری

<sup>1</sup> reinforcement learning

<sup>2</sup> policy learning

<sup>3</sup> self-critic policy gradient

<sup>4</sup> Transfer Learning (TL)

<sup>5</sup> PoBRL

<sup>6</sup> Maximal Marginal Relevance (MMR)

متوالی پیچیدگی را مدیریت کنند و یاد بگیرند جملات مرتبط حاوی اطلاعات را برای خلاصه انتخاب کنند. علاوه بر این یادگیری تقویتی امکان بهینه‌سازی همزمان اهداف متعدد مانند اهمیت، افزونگی و طول را فراهم می‌کند و موجب برقراری تعادل بین اهداف و تولید خلاصه‌های مختصر، مرتبط و غیر تکراری شوند.

سلیکیلماز<sup>۷</sup> و همکاران مدل کدگذار-کدگشای چندعامله را برای بهبود خلاصه‌سازی اسناد طولانی با استفاده از عامل تعامل‌کننده<sup>۸</sup> ارائه کرده‌اند. این مدل وظیفه کدگذاری یک متن طولانی را بین چندین عامل همکاری تقسیم می‌کند، که هر کدام مسئول یک زیربخش از ورودی هستند. این عوامل برای به اشتراک گذاشتن اطلاعات پایه‌ی جامع و ایجاد یک خلاصه متمرکز و منسجم با یکدیگر ارتباط برقرار می‌کنند. مدل ارائه شده در مقایسه با سایر مدل‌ها عملکرد بهتری دارد و خلاصه‌سازی اسناد طولانی با مدل‌های دنباله به دنباله را بهبود می‌بخشد.

## ۴-۲ یادگیری تقویتی برای ترکیب خلاصه‌های استخراجی و انتزاعی

از یادگیری تقویتی برای ترکیب ویژگی‌های استخراجی با خلاصه انتزاعی برای استفاده از هر دو نوع خلاصه‌ی خودکار با الهام از رفتار انسان استفاده می‌شود. این مدل‌ها ابتدا برجسته‌ترین جملات را از سند ورودی استخراج می‌کنند، سپس با استفاده از دو شبکه: شبکه‌های استخراج‌کننده و انتزاعی، آنها را انتزاع می‌کنند. به عنوان مثال لیو<sup>۹</sup> و همکاران یک چارچوب متخاصم را پیشنهاد می‌کنند که مدل‌های انتزاعی و استخراجی را همزمان با استفاده از گرادیان خط مشی برای بهینه‌سازی مدل انتزاعی برای خلاصه‌ای با پاداش بالا، آموزش می‌دهد که منجر به خلاصه‌ای منسجم‌تر می‌شود [۱۶]. همچنین چن و بانسال<sup>۱۰</sup> یک مدل خلاصه‌سازی سریع پیشنهاد کردند که جملات برجسته را استخراج می‌کرد و سپس با استفاده از گرادیان خط مشی سطح جمله مبتنی بر یادگیری تقویتی بازنویسی می‌کرد [۱]. کریسینسکی<sup>۱۱</sup> و همکاران دو روش برای افزایش سطح انتزاع در خلاصه‌سازی پیشنهاد می‌کنند: تجزیه رمزگشا به یک شبکه متنی و یک مدل زبانی از پیش آموزش‌دیده، و بهبود معیار جدید از طریق یادگیری خط‌مشی. تکنیک اول شامل یک شبکه‌ی محتوایی<sup>۱۲</sup> و یک مدل زبانی از پیش آموزش‌دیده است. شبکه‌ی محتوایی بخش‌های مرتبط از سند منبع را بازیابی کرده و آنها را فشرده می‌کند. مدل زبان از پیش آموزش‌حوی دانش قبلی در مورد تولید زبان است. این تفکیک مسئولیت‌ها امکان استخراج بهتر و تولید جملات مختصر را فراهم می‌کند. تکنیک دوم شامل معرفی یک معیار جدید است که از طریق یادگیری خط مشی بهینه می‌شود. این معیار مدل را به تولید عبارات بدیع که در سند منبع وجود نداشته‌اند تشویق می‌کند. با ترکیب این معیار جدید با معیار روژ که همپوشانی کلمات را با خلاصه حقیقت پایه اندازه

<sup>7</sup>Celikyilmaz

<sup>8</sup>communicating agent

<sup>9</sup>Liu

<sup>10</sup>Chen and Bansal

<sup>11</sup>Kryscinski

<sup>12</sup>contextual network

گیری می‌کند، مدل قادر به تولید خلاصه‌های انتزاعی با عملکرد بالا در همپوشانی کلمات می‌شود [۱۲].

### ۳-۴ یادگیری تقویتی برای ایجاد معیارها و پاداش‌های جدید

خلاصه‌سازی اسناد، مانند سایر کارهای مولد زبان، اغلب به دلیل استفاده از اهداف آموزشی مبتنی بر درست‌نمایی بیشینه<sup>۱۳</sup> مورد انتقاد قرار گرفته است. درست‌نمایی بیشینه کیفیت خلاصه‌ی تولید شده را در نظر نمی‌گیرد و ممکن است خلاصه‌هایی تولید کند که فقط یک کپی از اسناد ورودی هستند یا پر از کلمات بی‌معنی هستند. به همین دلیل، یادگیری تقویتی به عنوان جایگزینی برای بهینه‌سازی مستقیم مدل‌ها بر روی معیارهای ارزیابی و پاداش صریح به کیفیت پیش‌بینی‌های مدل استفاده شده است [۲۴]. معیارهای ارزیابی خلاصه‌سازی مانند روژ-۱<sup>۱۴</sup>، روژ-۲<sup>۱۵</sup>، روژ-ال<sup>۱۶</sup> و امتیازبرت<sup>۱۷</sup> به عنوان پاداش در رویکردهای یادگیری تقویتی استفاده شده است. با این حال، پارنل و همکاران استدلال می‌کند که استفاده از امتیازات روژ به عنوان پاداش، جنبه‌های مهم خلاصه‌سازی، مانند خوانایی، روان بودن و اشتراک اطلاعات بین اسنادی در خلاصه‌سازی چند سندی را نادیده می‌گیرد و یک پاداش پوشش اصلاح شده همراه با یک برآوردگر گرادیان سیاست مبتنی بر اصول (ریلکس)<sup>۱۸</sup> را پیشنهاد می‌دهند [۲۴، ؟]. ریلکس یک برآوردگر گرادیان خط مشی<sup>۱۹</sup> با واریانس کم و بدون سوگیری<sup>۲۰</sup> است که برای مسائل یادگیری تقویتی با فضاهای کنش مداوم، مانند خلاصه‌سازی متن، مناسب است [۶].

در عبارت ۱-۴ تابع زیان ارائه شده برحسب ریلکس نمایش داده شده است. بخش اول این عبارت سیاست را به تولید خروجی‌هایی با پاداش مورد انتظار بالا و بخش دوم به تولید خروجی‌های مشابه خروجی‌های قبلی تشویق می‌کند. در این عبارت  $r$  نشان دهنده‌ی پاداش  $c_\phi(\tilde{z})$  یک متغیر کنترلی از پارامترهای است که انتظار می‌رود با پاداش کاهش واریانس همبستگی داشته باشد.  $p(y_s)$  احتمال دنباله مشاهده شده خروجی  $y_s$  است.  $z$  دنباله نمونه‌های  $Gumbel - Softmax$  است.  $\tilde{z}$  دنباله ای از نمونه‌ها از یک توزیع  $Gumbel - Softmax$  مشروط بر  $y_s$  است.

$$L_{RELAX} = -[r - c_\phi(\tilde{z})] \log p(y^s) + c_\phi(z) - c_\phi(\tilde{z}) \quad (1-4)$$

<sup>13</sup>maximum likelihood

<sup>14</sup>ROUGE-1

<sup>15</sup>ROUGE-2

<sup>16</sup>ROUGE-L

<sup>17</sup>BERTScore

<sup>18</sup>modified coverage reward along with a principled policy gradient estimator (RELAX)

<sup>19</sup>policy

<sup>20</sup>bias

## ۴-۴ یادگیری تقویتی برای ایجاد خلاصه متناسب با نیاز کاربر

در خلاصه‌سازی متن، یادگیری تقویتی می‌تواند نقش مهمی به عنوان یک رویکرد پیشرفته برای ارائه خلاصه‌های متناسب با نیاز کاربر ایفا کند. با استفاده از یادگیری تقویتی، سیستم‌ها قادر به تحلیل و فهم متن‌ها و درک نیازهای کاربران می‌شوند، سپس با اعمال تصمیمات متناسب، خلاصه‌هایی ایجاد می‌کنند که بیان‌کننده اصلی‌ترین اطلاعات و مفاهیم موجود در متن اصلی هستند. این رویکرد توانایی ارائه خلاصه‌های متناسب با نیازهای کاربر را بهبود می‌بخشد و تجربه خواندن و درک محتوای متن را بهبود می‌بخشد. همچنین، با استفاده از یادگیری تقویتی، سیستم‌ها قادر به بهبود خودکار خلاصه‌سازی و افزایش کیفیت خلاصه‌های تولید شده هستند. سایر روش‌های خلاصه‌سازی به کاربران اجازه نمی‌دهند، سلیقه‌ی خود را برای کنترل جنبه‌های مختلف خلاصه‌های تولید شده نشان بدهند.

مدل کنترل‌سام<sup>۲۱</sup> با افزودن توکن‌های کنترلی به ابتدای متن ورودی و استفاده از یک مدل کدگذار-کدگشا به کاربران اجازه‌ی اعمال ویژگی‌های مورد نیازهای خود بر خلاصه را می‌دهند. به عنوان مثال برای کنترل طول خلاصه خروجی ده طول مجزا تعریف می‌شود و هریک توکن‌های کنترلی نشانگر یکی از این طول‌ها هستند. هدف آموزش این مدل از طریق تابع زیان درست‌نمایی بیشینه<sup>۲۲</sup> است [۵]. این هدف آموزش هیچ سیگنال نظارتی صریحی ندارد. برای حل این مشکل چان<sup>۲۳</sup> و همکاران با اعمال محدودیت بر روی هدف آموزشی با استفاده از فرآیند تصمیم‌گیری مارکوف محدود<sup>۲۴</sup> یک چهارچوب خلاصه‌سازی پیشنهاد کرده‌اند که شامل یک تابع پاداش همراه با مجموعه‌ای از محدودیت‌ها است و کنترل خلاصه‌سازی را تسهیل می‌کند. هدف عامل بیشینه کردن پاداش مورد انتظار در عین اعمال محدودیت بر هزینه‌ها است. با داشتن این هدف، تصمیم‌گیرنده سعی می‌کند سیاستی را انتخاب کند که منجر به بیشینه کردن پاداش کلی تجمعی در طول زمان شود، در حالی که محدودیت‌ها بر هزینه‌ها رعایت شوند. این هدف مدل را تشویق می‌کند که خلاصه‌ای شبیه خلاصه‌ی تولید شده توسط انسان تولید کند. با استفاده از این مدل کاربران می‌توانند طول، میزان فشردگی و محتوای خلاصه را کنترل کنند به عنوان مثال توضیحات یک محصول را به گونه‌ای خلاصه کند که در یک محدودیت کلمه در تبلیغات آنلاین قرار گیرد. برای تبدیل مسئله محدود به مسئله بدون محدودیت از ساده‌سازی لاگرانژ<sup>۲۵</sup> و برای بهینه‌سازی از الگوریتم بهینه‌سازی مبتنی بر گرادیان، مانند ادامه استفاده می‌شود. برای اندازه‌گیری شباهت بین خلاصه خروجی و مرجع بر اساس تعبیه‌های متنی برت به عنوان تابع پاداش از امتیازبرت استفاده می‌شود. برای کنترل تمرکز خلاصه بر روی یک موجودیت نامدار<sup>۲۶</sup> ابتدا ارجاع موجودیت نامدار به سند اضافه می‌شود سپس یک محدودیت سوال و جواب اعمال می‌شود. این محدودیت بر روی امتیاز اف-۱ خروجی یک مدل سوال جواب که ورودی آن شامل یک سوال راجع به موجودیت نامدار و خلاصه‌ی تولید

<sup>21</sup>controlSum

<sup>22</sup>maximum likelihood loss


<sup>23</sup>Chan

<sup>24</sup>Constrained Markov Decision Process (CMDP)

<sup>25</sup>Lagrangian relaxation

<sup>26</sup>named entity

شده است اعمال می‌شود. علاوه بر این دو محدودیت عدم تکرار برای گرم<sup>۲۷</sup> و موجودیت‌های درخواستی برای افزایش خوانایی و کاهش تکرار در متن اعمال می‌شود. مدل اینت‌سام<sup>۲۸</sup> یک مدل خلاصه‌سازی تعاملی با هدف خلاصه کردن اطلاعات مهم بر اساس کوئری‌های<sup>۲۹</sup> کاربر و ارائه کوئری پیشنهادی برای کمک به کاربر است. در ابتدا این مدل یک خلاصه‌ی اولیه تولید می‌کند و به کاربر نمایش می‌دهد سپس یک کوئری از کاربر دریافت می‌کند و خلاصه‌ی اولیه به همراه پاسخ کوئری را به کاربر نمایش می‌دهد. برای ارزیابی مدل ارائه شده مساحت منحنی بازیابی<sup>۳۰</sup> بر اساس طول خلاصه معرفی شده است که ستون عمودی آن امتیاز بازیابی روژ و ستون افقی آن طول خلاصه مرجع می‌باشد و مساحت بیشتر زیر منحنی نشان دهنده‌ی مدل بهتر است. یک نمونه از این نمودار در شکل ۴-۱ نمایش داده شده است [۲۷].



شکل ۴-۱: یک نمونه از نمودار منحنی بازیابی بر اساس طول [۲۷]  
این نمودار دو تعامل متفاوت با سیستم خلاصه‌سازی را مقایسه می‌کند. هر نقطه نمایانگر خروجی هر مرحله تعامل با کاربر است.

شاپیرا و همکاران برای بهبود مدل اینت‌سام و بهبود سرعت عمل در پاسخ‌گویی، توانایی پردازش کامل متون طولانی و رعایت تعادل میان اطلاعات کلی مقاله و اطلاعات مورد نیاز کاربر یک مدل جدید ارائه داده‌اند. ورودی این مدل مجموعه‌ی اسناد، کوئری و تاریخچه‌ی تعاملات با کاربر به همراه خروجی قبلی است. در ابتدا تعبیه کوئری به تعبیه اسناد ورودی الحاق شده سپس امتیاز  $qMMR$  با استفاده از مدل  $RL - MMR$  محاسبه می‌شود. هدف این امتیاز ایجاد خلاصه‌ای شبیه به اسناد ورودی و کوئری

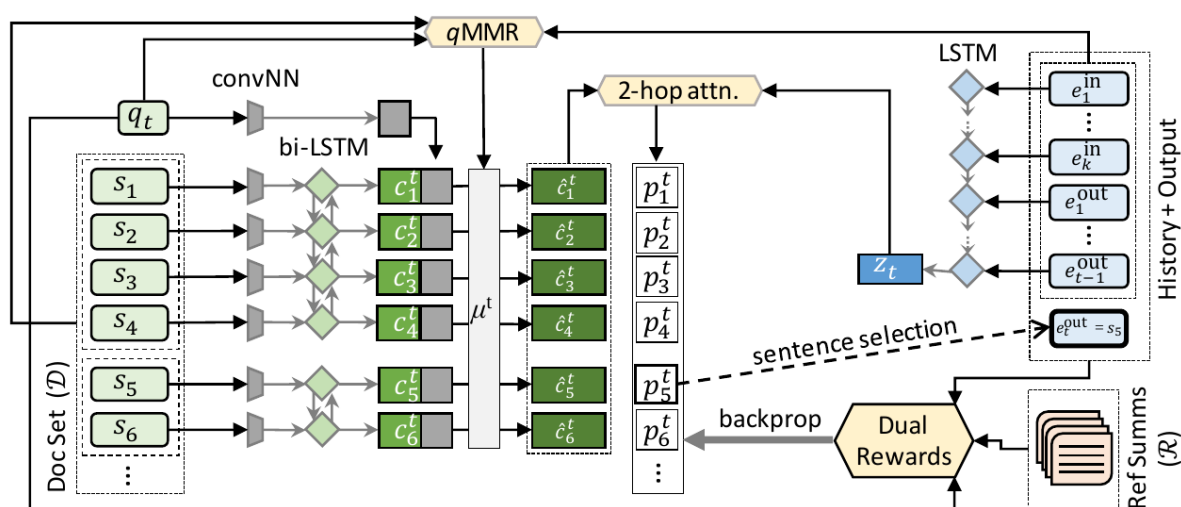
<sup>27</sup>trigram

<sup>28</sup>IntSumm

<sup>29</sup>query

<sup>30</sup>recall

و متفاوت از تاریخچه است. سپس با استفاده از مکانیزم توجه با مرکزیت دوگانه<sup>۳۱</sup> بر اساس کدگذاری به دست آمده از تاریخچه و مدل  $RL - MMR$  توزیع احتمال هر جمله را به دست می‌آید. مدل ام‌سام<sup>۳۲</sup> یک مدل خودرگرسیون<sup>۳۳</sup> است که برای آموزش آن از یادگیری تقویتی به همراه مکانیزم پاداش دوگانه استفاده می‌شود. معیار دلتا-روژ<sup>۳۴</sup> برای سنجش میزان اطلاعات اضافه‌ی خروجی نسبت به خروجی‌های قبلی و شباهت واژگانی و معنایی برای سنجش میزان شباهت خروجی به کوئری به عنوان پاداش استفاده شده‌اند. مدل  $RL - MMR$  موجب افزایش سرعت پردازش اطلاعات در مدل و پردازش کامل مجموعه‌ی اسناد و مکانیزم پاداش دوگانه تعادل موجب ایجاد تعادل اطلاعات می‌شود. ساختار مدل در شکل ۲-۴ نشان داده شده است [۲۶].



شکل ۲-۴: معماری مدل ام‌سام [۲۶]

<sup>31</sup>two hub attention

<sup>32</sup>MSumm

<sup>33</sup>Autoregressive

<sup>34</sup>Delta-ROUGE



## فصل پنجم

### جمع بندی

به طور خلاصه در این پژوهش ما پیشرفت‌های اخیر خلاصه‌سازی متن انتزاعی را با استفاده از مدل‌های یادگیری عمیق، مدل‌های یادگیری تقویتی و مدل‌های مبتنی بر ساختار بررسی کرده‌ایم. ما در مورد رویکرد‌های مختلفی که پیشنهاد شده است و چالش‌هایی که هنوز باید پرداخته شوند، بحث کرده‌ایم. مدل‌های یادگیری عمیق به ویژه هنگامی که با یادگیری تقویتی ترکیب شوند، برای خلاصه‌سازی متن انتزاعی مؤثر هستند. با این که، آموزش این مدل‌ها از نظر محاسباتی پرهزینه است و خلاصه‌ی تولید شده توسط این مدل‌های ممکن است به اندازه خلاصه‌های نوشته شده توسط انسان روان یا آموزنده نباشد زیرا مدل‌های یادگیری عمیق بر روی مجموعه داده‌های بزرگی دادگان آموزش داده می‌شوند که جمع‌آوری و برچسب‌گذاری آن زمان‌بر و پرهزینه است.

مدل‌های مبتنی بر ساختار پتانسیل رفع برخی از محدودیت‌های مدل‌های یادگیری عمیق را دارند. این مدل‌ها می‌توانند دانش حوزه و قواعد زبانی را در خود جای دهند که می‌تواند به بهبود کیفیت خلاصه‌های تولید شده کمک کند. با این حال، آموزش این مدل‌ها دشوار است و قابل تعمیم به حوزه‌های جدید نیست.

به طور کلی، در سال‌های اخیر پیشرفت قابل توجهی در خلاصه‌سازی متن انتزاعی حاصل شده است و رویکردهای مختلفی برای کاهش افزونگی و افزایش خوانایی خلاصه‌ها ارائه شده است با این حال، هنوز چالش‌هایی زیادی وجود دارد. در حال حاضر، تحقیقات خلاصه‌سازی انتزاعی بر یافتن مناسب‌ترین مدل‌های از پیش آموزش دیده و چگونگی تطبیق بازنمایی‌های به دست آمده از این مدل‌ها برای بهبود کیفیت خلاصه‌ها و نزدیک‌تر کردن آن‌ها به خلاصه‌سازی انسانی متمرکز است.

## منابع و مراجع

- [1] Chen, Yen-Chun and Bansal, Mohit. Fast abstractive summarization with reinforcement selected sentence rewriting. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 675–686, 2018.
- [2] Child, Rewon, Gray, Scott, Radford, Alec, and Sutskever, Ilya. Generating long sequences with sparse transformers, 2019.
- [3] El-Kassas, Wafaa S., Salama, Cherif R., Rafea, Ahmed A., and Mohamed, Hoda K. Automatic text summarization: A comprehensive survey. Expert Systems with Applications, 165:113679, 2021.
- [4] Elman, Jeffrey L. Finding structure in time. Cognitive science, 14(2):179–211, 1990.
- [5] Fan, Angela, Grangier, David, and Auli, Michael. Controllable abstractive summarization. In Proceedings of the 2nd Workshop on Neural Machine Translation and Generation, pages 45–54, Melbourne, Australia, July 2018. Association for Computational Linguistics.
- [6] Grathwohl, Will, Choi, Dami, Wu, Yuhuai, Roeder, Geoffrey, and Duvenaud, David Kristjanson. Backpropagation through the void: Optimizing control variates for black-box gradient estimation. ArXiv, abs/1711.00123, 2017.
- [7] Hochreiter, Sepp and Schmidhuber, Jürgen. Long short-term memory. Neural computation, 9(8):1735–1780, 1997.

- [8] Idris, Norisma, Alomari, Ayham, Sabri, Aznul Qalid Md, and Alsmadi, Izzat. Deep reinforcement and transfer learning for abstractive text summarization: A review. *Computer Speech and Language*, 71:101276, 2022.
- [9] Ishikawa, Kai, Ando, Shinichi, and Okumura, Akitoshi. Hybrid text summarization method based on the tf method and the lead method. In *NTCIR Conference on Evaluation of Information Access Technologies*, 2001.
- [10] Keneshloo, Yaser, Ramakrishnan, Naren, and Reddy, Chandan K. Deep transfer reinforcement learning for text summarization. *ArXiv*, abs/1810.06667, 2018.
- [11] Kitaev, Nikita, Kaiser, Lukasz, and Levskaya, Anselm. Reformer: The efficient transformer. In *International Conference on Learning Representations*, 2019.
- [12] Kryscinski, Wojciech, Paulus, Romain, Xiong, Caiming, and Socher, Richard. Improving abstraction in text summarization. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 1808–1817, Brussels, Belgium, October-November 2018. Association for Computational Linguistics.
- [13] Lee, Chang-Shing, Jian, Zhi-Wei, and Huang, Lin-Kai. A fuzzy ontology and its application to news summarization. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 35(5):859–880, 2005.
- [14] Lewis, Mike, Liu, Yinhan, Goyal, Naman, Ghazvininejad, Marjan, Mohamed, Abdelrahman, Levy, Omer, Stoyanov, Veselin, and Zettlemoyer, Luke. BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7871–7880, Online, July 2020. Association for Computational Linguistics.

- [15] Liang, Yunlong, Meng, Fandong, Zhou, Chulun, Xu, Jinan, Chen, Yufeng, Su, Jinsong, and Zhou, Jie. A variational hierarchical model for neural cross-lingual summarization. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 2088–2099, Dublin, Ireland, May 2022. Association for Computational Linguistics.
- [16] Liu, Linqing, Lu, Yao, Yang, Min, Qu, Qiang, Zhu, Jia, and Li, Hongyan. Generative adversarial network for abstractive text summarization. In Proceedings of the AAAI conference on artificial intelligence, volume 32, 2018.
- [17] Liu, Qi, Kusner, Matt J, and Blunsom, Phil. A survey on contextual embeddings. arXiv preprint arXiv:2003.07278, 2020.
- [18] Luhn, Hans Peter. The automatic creation of literature abstracts. IBM Journal of research and development, 2(2):159–165, 1958.
- [19] Ma, Tinghuai, Pan, Qian, Rong, Huan, Qian, Yurong, Tian, Yuan, and Al-Nabhan, Najla Abdulrahman. T-bertsum: Topic-aware text summarization based on bert. IEEE Transactions on Computational Social Systems, 9:879–890, 2022.
- [20] Malliaros, Fragkiskos D. and Skianis, Konstantinos. Graph-based term weighting for text categorization. In Proceedings of the 2015 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining 2015, ASONAM '15, page 1473–1479, New York, NY, USA, 2015. Association for Computing Machinery.
- [21] Moratanch, N. and Chitrakala, S. A survey on abstractive text summarization. In 2016 International Conference on Circuit, Power and Computing Technologies (ICCPCT), pages 1–7, 2016.

- [22] Narendra, Andhale and Bewoor, Laxmi A. An overview of text summarization techniques. In 2016 international conference on computing communication control and automation (ICCUBE), pages 1–7. IEEE, 2016.
- [23] Pang, Bo, Nijkamp, Erik, Kryscinski, Wojciech, Savarese, Silvio, Zhou, Yingbo, and Xiong, Caiming. Long document summarization with top-down and bottom-up inference. In Findings of the Association for Computational Linguistics: EACL 2023, pages 1237–1254, 2023.
- [24] Parnell, Jacob, Unanue, Inigo Jauregi, and Piccardi, Massimo. A multi-document coverage reward for relaxed multi-document summarization. In Annual Meeting of the Association for Computational Linguistics, 2022.
- [25] Pilault, Jonathan, Li, Raymond, Subramanian, Sandeep, and Pal, Christopher. On extractive and abstractive neural document summarization with transformer language models. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 9308–9319, 2020.
- [26] Shapira, Ori, Pasunuru, Ramakanth, Bansal, Mohit, Dagan, Ido, and Amsterdamer, Yael. Interactive query-assisted summarization via deep reinforcement learning. In Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, pages 2551–2568, Seattle, United States, July 2022. Association for Computational Linguistics.
- [27] Shapira, Ori, Pasunuru, Ramakanth, Ronen, Hadar, Bansal, Mohit, Amsterdamer, Yael, and Dagan, Ido. Extending multi-document summarization evaluation to the interactive setting. In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, pages 657–677, Online, June 2021. Association for Computational Linguistics.

- [28] Sherborne, Tom and Lapata, Mirella. Meta-learning a cross-lingual manifold for semantic parsing. *Transactions of the Association for Computational Linguistics*, 11:49–67, 2023.
- [29] Su, DiJia, Su, Difei, Mulvey, John M., and Poor, H.Vincent. Optimizing multidocument summarization by blending reinforcement learning policies. *IEEE Transactions on Artificial Intelligence*, 4(3):416–427, 2023.
- [30] Su, Ming-Hsiang, Wu, Chung-Hsien, and Cheng, Hao-Tse. A two-stage transformer-based approach for variable-length abstractive summarization. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:2061–2072, 2020.
- [31] Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N, Kaiser, Lukasz, and Polosukhin, Illia. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [32] Xiong, Wenhan, Gupta, Anchit, Toshniwal, Shubham, Mehdad, Yashar, and tau Yih, Wen. Adapting pretrained text-to-text models for long text sequences. *ArXiv*, abs/2209.10052, 2022.
- [33] Yao, Kaichun, Zhang, Libo, Du, Dawei, Luo, Tiejian, Tao, Lili, and Wu, Yanjun. Dual encoding for abstractive text summarization. *IEEE transactions on cybernetics*, 50(3):985–996, 2018.
- [34] Zaheer, Manzil, Guruganesh, Guru, Dubey, Kumar Avinava, Ainslie, Joshua, Alberti, Chris, Ontanon, Santiago, Pham, Philip, Ravula, Anirudh, Wang, Qifan, Yang, Li, et al. Big bird: Transformers for longer sequences. *Advances in neural information processing systems*, 33:17283–17297, 2020.

- [35] Zhang, Jingqing, Zhao, Yao, Saleh, Mohammad, and Liu, Peter. Pegasus: Pre-training with extracted gap-sentences for abstractive summarization. In International Conference on Machine Learning, pages 11328–11339. PMLR, 2020.



# واژه‌نامه‌ی انگلیسی به فارسی

ا	ترنسفورمر . . . . . transformer
الگوریتم حداکثر سازی نقطه-محصول فرا	تعبیه . . . . . embedding
یادگیری . . . . . Meta-Learned Dot-Product	تعبیه نشانه . . . . . token embedding
Maximization	تنظیم . . . . . regularization
امتیازبرت . . . . . BERTScore	تنظیم دقیق پارامترها . . . . . fine-tuning
ب	توالی . . . . . sequence
بارت . . . . . BART	توجه با مرکزیت دوگانه . . . . . two hub
بازنمایی . . . . . Representation	attention
بازیابی . . . . . recall	توجه به خود . . . . . Self-attention
بیگ‌برد . . . . . Big Bird	توجه جامع . . . . . global attention
پ	توسعه . . . . . deploy
پراکنده . . . . . sparse	ج
پیش‌آموزش . . . . . pretraining	جامع . . . . . global
پگاسوس . . . . . PEGASUS	جملات فاصله‌افتاده . . . . . gap sentences
ت	جی‌پی‌تی . . . . . GPT
تابع زیان درست‌نمایی بیشینه maximum	چ
liklihood loss	چند معنایی . . . . . polysemy
ترای گرم . . . . . trigram	ح

long . . . . . حافظه‌ی بلند مدت طولانی	Lagrangian . . . . . ساده‌سازی لاگرانژ
short-term memory networks(LSTM)	relaxation
informative . . . . . حاوی اطلاعات مفید	bias . . . . . سوگیری
Maximal . . . . . حداکثر ارتباط حاشیه‌ای	ش
Marginal Relevance (MMR)	شبکه‌های عصبی بازگشتی . . .
خ	neural network (RNN)
policy . . . . . خط مشی	ع
Autoregressive . . . . . خود رگرسیون	عامل
د	عامل تعامل کننده . . .
maximum . . . . . درست‌نمایی بیشینه	agent
likelihood	عبارت مقدمه و بدنه . . .
locality- . . . . . درهم‌سازی حساس به مکان	phrase
sensitive hashing	عمل
Delta-ROUGE . . . . . دلتا-روژ	عمل پایین‌دست . . .
Divide-and-ConquerER . . . . . دنسر	ف
(DANCER)	فرا یادگیری . . . . .
bidirectional . . . . . دوسویه	ک
ر	کوئری . . . . .
ROUGE-L . . . . . روژ-ال	ل
ROUGE-1 . . . . . روژ-۱	لایه‌های برگشت‌پذیر . .
ROUGE-2 . . . . . روژ-۲	م
modified cover- . . . . . ریلکس	مقاطع زبانی . . . . .
age reward along with a principled policy	مجموعه‌ی دادگان . . . . .
gradient estimator (RELAX)	مدل موضوعی عصبی . . .
س	Model(NTM)

مدل مولد نقطه‌ای . . Pointer-Generator model	وظایف پایین‌دست . . downstream tasks ه
مکانیزم توکن سراسری . . . Global-token mechanism	هدف آموزش . . . . . training objective هستان‌شناسی . . . . . ontology
نمایش نهفته . . . . latent representation	هم‌پوشانی بلوک‌های توجه . Overlapping attention windows
و	ی
واحد بازگشتی دروازه‌ای gated recurrent unit (GRU)	یادگیری تقویتی reinforcement learning
وظایف . . . . . tasks	یادگیری خط مشی . . . policy learning

# واژه‌نامه‌ی انگلیسی به فارسی

A	مجموعه‌ی دادگان . . . . . Corpus
Agent . . . . . عامل	Cross-lingual . . . . . متقاطع زبانی
Autoregressive . . . . . خودرگرسیون	D
B	Decoder . . . . . کدگشا
Bart . . . . . بارت	Delta-rouge . . . . . دلتا-روژ
Bertscore . . . . . امتیازبرت	Deploy . . . . . توسعه
Bias . . . . . سوگیری	Divide-and-conquer (dancer) . . . . . دنسر
Bidirectional . . . . . دوسویه	Dot-product . . . . . نقطه-محصول
Big bird . . . . . بیگ‌برد	Downstream tasks . . . . . وظایف پایین‌دست
Block- . . . . . توجه به خود پراکنده‌ی بلوکی	E
sparse self-attention	Embedding . . . . . تعبیه
C	Encoder . . . . . کدگذار
Communicating . . . . . عامل تعامل‌کننده	F
agent	Fine-tuning . . . . . تنظیم دقیق پارامترها
فرآیند تصمیم‌گیری مارکوف محدود	G
Constrained markov decision process	Gap sentences . . . . . جملات فاصله‌افتاده
(cmdp)	Gated recurrent . . . . . واحد بازگشتی دروازه‌ای
Contextual network . . . . . شبکه‌ی محتوایی	unit (gru)

Global . . . . . جامع	Modified cover- . . . . . ریلکس
Global attention . . . . . توجه جامع	age reward along with a principled policy gradient estimator (relax)
Global-token . . . مکانیزم توکن سراسری . . . mechanism	N
Gpt . . . . . جی‌پی‌تی	Named entity . . . . . موجودیت نامدار
I	Neural topic . . . . . مدل موضوعی عصبی model(ntm)
Informative . . . . . حاوی اطلاعات مفید	O
L	Ontology . . . . . هستان‌شناسی
Lagrangian . . . . . ساده‌سازی لاگرانژ relaxation	Overlapping . . . هم‌پوشانی بلوک‌های توجه . attention windows
Latent representation . . . نمایش نهفته	P
Lead-and-body . . . عبارت مقدمه و بدنه phrase	Pegasus . . . . . پگاسوس
Locality- . . . درهم‌سازی حساس به مکان . . sensitive hashing (lsh)	Pointer-generator . . . مدل مولد نقطه‌ای . . model
Long . . . . . حافظه‌ی بلند مدت طولانی short-term memory networks(lstm)	Policy . . . . . خط مشی
M	Policy learning . . یادگیری خط مشی
Maximum . . . . . درست‌نمایی بیشینه likelihood	Polysemy . . . . . چند معنایی
Maximum . . . تابع زیان درست‌نمایی بیشینه likelihood loss	خود توجهی مبتنی بر ادغام بلوکی تقویت Pooling-augmented blockwise . . . . . attention شده
Meta-learned . . . . . فرا یادگیری	Pretraining . . . . . پیش‌آموزش
الگوریتم حداکثر سازی نقطه-محصول فرا Meta-learned dot-product . . . . . یادگیری maximization	Q
	Query . . . . . کوئری
	R

Recall . . . . . بازیابی	Self-critic . . . . . گرادیان خط مشی انتقادی . . . . . policy gradient
Recurrent . . . . . شبکه‌های عصبی بازگشتی neural network (rnn)	Sequence . . . . . توالی
Regularization . . . . . تنظیم	Sparse . . . . . پراکنده
Reinforcement . . . . . یادگیری تقویتی learning	T
Representation . . . . . بازنمایی	T-bertsum . . . . . تی‌برت‌سام
Reversible layers . . . . . لایه‌های برگشت‌پذیر	Tasks . . . . . وظایف
Rouge-1 . . . . . روژ-۱	Term frequency . . . . . فرکانس تکرار عبارت
Rouge-2 . . . . . روژ-۲	Token embedding . . . . . تعبیه نشانه
Rouge-l . . . . . روژ-ال	Training objective . . . . . هدف آموزش
S	Transformer . . . . . ترنسفورمر
Segment embedding . . . . . تعبیه قطعه	Trigram . . . . . ترای‌گرم
Self-attention . . . . . توجه به خود	Two hub . . . . . توجه با مرکزیت دوگانه . . . . . attention